机器学习三大基础模型
学习指南

线性回归 · 逻辑回归 · 支持向量机

基于 CSCI3230 (ESTR3108) *Fundamentals of Artificial Intelligence* 讲义整理

（Lecture 2 / 3 / 4，授课教师：Prof. Qi Dou，CUHK）

本指南包含什么？

- 三讲讲义的**完整知识梳理**：概念、公式、推导、结论，按逻辑重新组织；
- 讲义中**所有例题、Quiz 的完整解答过程**（带逐步数值计算）；
- 大量**讲义之外补充的例子**（标注为“补充例”）：每个抽象公式都配一个可以动手算的例子；
- 每章末**自检题**（附答案），附录含**公式速查表**与三讲**对照总结**。

阅读建议：第一遍通读概念与例题；第二遍只看加框的“核心结论/易错点”；考前用自检题与公式表快速回忆。

符号约定：m 为样本数，n 为特征数；$X \in \mathbb{R}^{m\times(n+1)}$ 为（已拼接全 1 列的）数据矩阵，$\Theta \in \mathbb{R}^{n+1}$ 为参数；上标 (i) 表示第 i 个样本，下标表示第几个特征。

本指南为个人学习整理的笔记，图表为原创重绘，如与课程官方材料有出入，以课程材料为准。

三讲知识地图

三讲内容一脉相承：**从“拟合数值”到“预测类别”再到“最大间隔分类”**，是一条非常典型的机器学习主线，它们共享同一套矩阵记号与优化工具，差别在于*假设函数*和*损失函数*的选择。

	Lecture 2 线性回归	**Lecture 3 逻辑回归**	**Lecture 4 SVM**
任务	回归（预测连续值）	分类（输出概率）	分类（输出决策边界）
假设函数	$\hat{y} = X\Theta$	$P(\hat{y}{=}1\|X) = \sigma(X^\top\Theta)$	$f(x) = w^\top x + b$
损失/目标	残差平方和 RSS	交叉熵（负对数似然）	最大化间隔（$\min \frac{1}{2}\|w\|^2$）
优化	有解析解（正规方程）	无解析解 $\to$ 梯度下降	凸二次规划（对偶 + SMO）
核心工具	矩阵微分、投影几何	概率、MLE、凸性	拉格朗日对偶、KKT、核技巧
进阶话题	岭回归 / Lasso	交叉熵凸性证明	核 SVM / 软间隔 SVM

一条主线——最小化“预测与真实的差距”

三个模型都做同一件事：定义模型 $\Rightarrow$ 定义损失 $\Rightarrow$ 优化参数。

1. **线性回归**：差距 = 平方误差；凸函数 $\Rightarrow$ 求导置零得解析解。
2. **逻辑回归**：差距 = 交叉熵；凸函数但无解析解 $\Rightarrow$ 梯度下降。
3. **SVM**：换一个思路——不只看“分对没有”，而是要求“分得尽量开” $\Rightarrow$ 约束优化 $\Rightarrow$ 对偶问题。

读懂这条主线，三讲就是同一套方法的三个变奏。

目录

三讲知识地图 1

1 线性回归（Lecture 2） 3
1.1 什么是回归：从“函数拟合”说起 . . . 3
1.2 基本形式化：从单变量到矩阵记号 . . . 4
1.3 目标函数：残差平方和 RSS . . . 5
1.4 一元情形：手工求解全过程 . . . 5
1.5 多元情形：解析解与凸性 . . . 7
1.6 深入理解一：$X^\top X$ 何时可逆? . . . 8
1.7 深入理解二：子空间投影视角 . . . 8
1.8 偏差–方差权衡与过拟合 . . . 9
1.9 收缩方法：岭回归与 Lasso . . . 10
1.10 本章小结 . . . 12

2 逻辑回归（Lecture 3） 13
2.1 分类问题 . . . 13
2.2 从线性回归到逻辑回归 . . . 14
2.3 逻辑回归模型 . . . 15
2.4 优化：从监督准则到交叉熵 . . . 16
2.5 深入理解：交叉熵损失为什么是凸的 . . . 17
2.6 优化：梯度下降 . . . 18
2.7 逻辑回归的梯度下降 . . . 20
2.8 本章小结 . . . 20

3 支持向量机（Lecture 4） 21
3.1 线性分类器回顾 . . . 21
3.2 SVM 的目标：最宽的路 . . . 22
3.3 工具准备：拉格朗日乘子、对偶、KKT . . . 23
3.4 SVM 的对偶问题：完整推导 . . . 24
3.5 完整玩具例子：8 点 SVM 手算 . . . 26
3.6 核 SVM：处理非线性数据 . . . 27
3.7 软间隔 SVM：允许一点噪声 . . . 29
3.8 本章小结 . . . 30

4 总结、速查表与易错点 31
4.1 三讲公式速查表 . . . 31
4.2 讲义 Quiz 全解索引 . . . 33
4.3 常见易错点清单（考前自查） . . . 33
4.4 三讲对照总表 . . . 34
4.5 建议的复习路径 . . . 34

1 线性回归（Lecture 2）

本章学习目标

- 理解**回归**问题的定义，以及“线性假设”的含义；
- 熟练书写线性回归的**标量形式与矩阵形式**（含全 1 列、参数吸收等记号技巧）；
- 掌握**残差平方和 (RSS)** 目标函数，以及一元情形的手工推导、多元情形的矩阵解析解；
- 理解**凸性**为什么保证“求导置零”即可得到全局最优；
- 了解两个深入视角：$X^\top X$ 的可逆性条件、子空间投影几何；
- 理解**偏差–方差权衡**，掌握岭回归与 Lasso 的动机与区别。

1.1 什么是回归：从“函数拟合”说起

回归是一种统计方法: 估计*因变量* (outcome / response, 记作 Y) 与*自变量* (predictor / feature, 记作 $x_1, \dots, x_n$) 之间的关系。例如：用年龄、性别、饮食（自变量）来研究身高（因变量）。

把回归看作一个“程序”:

回归 = 一台预测机器

- **输入**：自变量（特征）$x_1, \dots, x_n$；
- **输出**：因变量（预测值）y；
- **训练**：拿一批已知 (x, y) 的数据，找一个函数 f 尽量贴近真实规律。

线性回归（linear regression）。 假设输入与输出之间的关系是*线性的*:

- 直观上：函数图像是直线（1 个特征）或平面/超平面（多个特征）；
- 数学上：f 是线性的当且仅当 $f(u+v) = f(u) + f(v)$ 且 $f(cu) = cf(u)$。

为什么是“线性”而不是别的? 线性关系简单但非常有用：生活中的线性关系随处可见，如滑动摩擦力与正压力、重力与质量、路程与速度等。因此用它作为第一个模型非常自然。

贯穿全课的例子：用面积预测租金。 想知道 CUHK 附近公寓的租金与面积（m^2）之间的关系，已有如下数据:

Index	1	2	3	4	5
面积 x（m^2）	40	92	37	124	88
租金 y（HKD）	134 072	182 241	134 731	204 325	187 375

问题：给定任意面积，能否预测租金? 把数据画出来（见图 1），散点大致沿一条直线分布——这正是“线性假设”的来源。

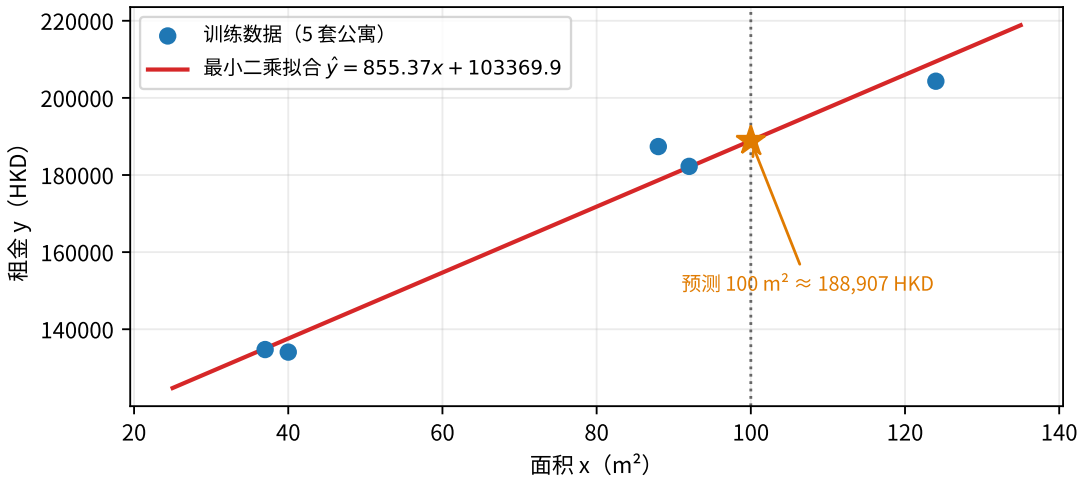


图 1: 公寓面积与租金：5 个训练点、最小二乘直线与 $100\,\mathrm{m}^2$ 处的预测值。

1.2　基本形式化：从单变量到矩阵记号

把“智能机器”看作带输入输出的函数

$$f:\ \mathcal{X}\to\mathcal{Y},\qquad \mathcal{X}\subset\mathbb{R}^n,\ \ \mathcal{Y}\subset\mathbb{R}.$$

在“面积–租金”例子里，$\mathcal{X}$ 是公寓面积的取值范围，$\mathcal{Y}$ 是租金的取值范围。

目标：用训练数据找一个尽可能接近真实 f 的近似映射 $\hat{f}:\mathcal{X}\to\mathcal{Y}$。

单特征情形（univariate）。 只有一个特征 x 时，假设它们满足一条直线：

$$\hat{y}=\hat{f}_{\theta_0,\theta_1}(x)=\theta_1 x+\theta_0. \tag{1}$$

只要找到“最好的”θ_1,θ_0，就能对任何输入的面积预测租金。

多特征情形（multivariate）。 若租金还依赖别的因素（离地铁站距离、楼层等），就需要 n 个特征 $x_1,\dots,x_n$：

$$\hat{y}=\hat{f}_{\theta_0,\dots,\theta_n}(x_1,\dots,x_n)=\theta_0+\theta_1x_1+\cdots+\theta_nx_n. \tag{2}$$

写成矩阵形式：$\hat{y}=\hat{f}_{\Theta,\theta_0}(X)=X^\top\Theta+\theta_0$，其中 $\Theta=(\theta_1,\dots,\theta_n)^\top$、$X=(x_1,\dots,x_n)^\top$。请记住：$\theta_0$ 与 Θ 都是要*从训练数据中学习*的参数。

多样本 + 吸收偏置项（关键记号技巧）。 设 m 个样本 $X^{(1)},\dots,X^{(m)}\in\mathbb{R}^n$，标签为 $y^{(1)},\dots,y^{(m)}$。把所有样本按行堆成**数据矩阵** $X\in\mathbb{R}^{m\times n}$（行 = 样本，列 = 特征）：

$$X=\begin{pmatrix}-\ X^{(1)\top}\ -\\ \vdots\\ -\ X^{(m)\top}\ -\end{pmatrix}=\begin{pmatrix}x_1^{(1)} & \cdots & x_n^{(1)}\\ \vdots & \ddots & \vdots\\ x_1^{(m)} & \cdots & x_n^{(m)}\end{pmatrix}.$$

所有样本一起预测：$\hat{Y}=\hat{f}_{\Theta,\theta_0}(X)=X\Theta+\theta_0$，$\hat{Y}=(\hat{y}^{(1)},\dots,\hat{y}^{(m)})^\top$。

为了写法简洁，通常把偏置 θ_0 **吸收**进 Θ：给 X 左边插入一列全 1，参数向量最上面加 θ_0：

$$X=\begin{pmatrix}1 & x_1^{(1)} & \cdots & x_n^{(1)}\\ \vdots & \vdots & \ddots & \vdots\\ 1 & x_1^{(m)} & \cdots & x_n^{(m)}\end{pmatrix}\in\mathbb{R}^{m\times(n+1)},\qquad \Theta=\begin{pmatrix}\theta_0\\ \theta_1\\ \vdots\\ \theta_n\end{pmatrix}\in\mathbb{R}^{n+1},$$

于是得到贯穿三讲的**简化矩阵形式**:

$$\boxed{\hat{Y} = \hat{f}_\Theta(X) = X\Theta} \tag{3}$$

如何解读 $X\Theta$?

按列看:

$$X\Theta = \theta_1 \begin{pmatrix} x_1^{(1)} \\ \vdots \\ x_1^{(m)} \end{pmatrix} + \theta_2 \begin{pmatrix} x_2^{(1)} \\ \vdots \\ x_2^{(m)} \end{pmatrix} + \cdots + \theta_n \begin{pmatrix} x_n^{(1)} \\ \vdots \\ x_n^{(m)} \end{pmatrix},$$

即：*把每个特征列按系数加权混合*，得到每个样本的预测值。θ_j 越大，第 j 个特征对预测的贡献越大。

几何图像。 带标签的数据点 $(x_1^{(i)}, \ldots, x_n^{(i)}, y^{(i)})$ 位于 $(n+1)$ 维空间；线性回归要拟合的对象是其中一张 n 维超平面（$n=1$ 时是直线，$n=2$ 时是平面）。

1.3　目标函数：残差平方和 RSS

怎样算“最好”的 Θ? 先看能否“完美贴合”训练数据。直观上要度量 *预测值* $\hat{f}(X^{(i)})$ *与真实标签* $y^{(i)}$ *的距离*，而且这个距离应当是 Θ 的函数。

定义目标函数（objective / cost function）$J(\Theta)$, 取**残差平方和**（Residual Sum of Squares, RSS）:

$$J(\Theta) = \sum_{i=1}^{m} \left(\hat{f}_\Theta(X^{(i)}) - y^{(i)} \right)^2 = \left\| \hat{f}_\Theta(X) - Y \right\|_2^2 = \|X\Theta - Y\|_2^2 . \tag{4}$$

通过最小化 RSS 求近似解的方法称为**普通最小二乘**（ordinary least squares, OLS）。

几何直觉

每个样本的“残差” = 拟合平面（或直线）在该点的高度与真实标签（红点）之差。RSS 就是所有残差平方的加和——把“拟合好坏”压缩成一个非负数，越小越好。

1.4　一元情形：手工求解全过程

先解决只有一个特征的问题（先不考虑吸收偏置的记号，保留 θ_0, θ_1 分开）:

$$J(\theta_0, \theta_1) = \sum_{i=1}^{m} \left(\theta_1 x^{(i)} + \theta_0 - y^{(i)} \right)^2 .$$

把二次项展开并配方整理（这一步是纯代数，讲义给出结论）。为书写简洁，记

$$S_{xx} = \sum_{i=1}^{m} \left(x^{(i)} - \bar{x} \right)^2, \qquad S_{xy} = \sum_{i=1}^{m} (x^{(i)} - \bar{x})(y^{(i)} - \bar{y}), \qquad S_{yy} = \sum_{i=1}^{m} (y^{(i)} - \bar{y})^2,$$

则

$$J(\theta_0, \theta_1) = \underbrace{S_{xx} \Big(\theta_1 - \frac{S_{xy}}{S_{xx}} \Big)^2}_{\text{只含数据}} + \underbrace{m \big(\theta_0 - (\bar{y} - \theta_1 \bar{x}) \big)^2}_{\text{含}\theta_0,\theta_1} + \underbrace{S_{yy} - \frac{S_{xy}^2}{S_{xx}}}_{\text{与参数无关的常数}} , \tag{5}$$

其中 $\bar{x} = \frac{1}{m} \sum x^{(i)}$、$\bar{y} = \frac{1}{m} \sum y^{(i)}$ 分别是 x 与 y 的均值。

为什么“让前两项等于 0”就是最优？

前两项都是*平方乘正系数*的形式，恒 ≥ 0，且第三项完全不依赖待优化参数。因此 J 的最小值恰在前两项同时为 0 时取得：

$$\theta_1^* = \frac{\sum (x^{(i)} - \bar{x})(y^{(i)} - \bar{y})}{\sum (x^{(i)} - \bar{x})^2}, \qquad \theta_0^* = \bar{y} - \theta_1^* \bar{x}.$$

这正是所有教科书的“最小二乘公式”。第二项先在给定 θ_1^* 后对 θ_0 取零即可。

例题 1.1　讲义 Quiz：手算一条回归线

用最小二乘求 $y = \theta_1 x + \theta_0$ 在数据 $(9, 21)$，$(3, 6)$，$(12, 27)$ 上的解。
解答（选 B）。先算均值：

$$\bar{x} = \frac{9 + 3 + 12}{3} = 8, \qquad \bar{y} = \frac{21 + 6 + 27}{3} = 18.$$

再算两个核心和：

$$\sum (x^{(i)} - \bar{x})(y^{(i)} - \bar{y}) = (1)(3) + (-5)(-12) + (4)(9) = 3 + 60 + 36 = 99,$$

$$\sum (x^{(i)} - \bar{x})^2 = 1^2 + (-5)^2 + 4^2 = 1 + 25 + 16 = 42.$$

于是

$$\theta_1^* = \frac{99}{42} = \frac{33}{14} \approx 2.3571, \qquad \theta_0^* = 18 - \frac{33}{14} \times 8 = \frac{126 - 132}{7} = -\frac{6}{7} \approx -0.8571.$$

即 $\hat{y} \approx 2.3571x - 0.8571$，对应选项 B。（可用三个点的预测值检查：$\hat{y} = 20.36,\ 6.21,\ 27.43$，与 $21, 6, 27$ 很接近。）

例题 1.2　补充例：再走一遍完整流程（简单整数数据）

数据 $(0, 1), (1, 2), (2, 4)$，求最小二乘直线。
解。$\bar{x} = 1,\ \bar{y} = 7/3$。

$$\sum (x - \bar{x})(y - \bar{y}) = (-1)\left(-\frac{4}{3}\right) + 0 \cdot \left(-\frac{1}{3}\right) + 1 \cdot \frac{5}{3} = \frac{4}{3} + \frac{5}{3} = 3,$$

$$\sum (x - \bar{x})^2 = 1 + 0 + 1 = 2 \ \Rightarrow\ \theta_1^* = \frac{3}{2}, \quad \theta_0^* = \frac{7}{3} - \frac{3}{2} = \frac{5}{6}.$$

所以 $\hat{y} = \frac{3}{2}x + \frac{5}{6}$。三个残差（预测值减真实标签）为 $-\frac{1}{6}, +\frac{1}{3}, -\frac{1}{6}$，SSE $= \frac{1}{36} + \frac{1}{9} + \frac{1}{36} = \frac{1}{6} \approx 0.167$。注意 $\sum$ 残差 $= -\frac{1}{6} + \frac{1}{3} - \frac{1}{6} = 0$：*带截距的最小二乘残差和恒为 0*（因为 $\theta_0^* = \bar{y} - \theta_1^* \bar{x}$ 保证了拟合直线过点 $(\bar{x}, \bar{y})$）。

例题 1.3　补充例：租金例子的完整拟合与预测

对前面 5 个数据点手算（或用任意工具验证）：

$$\bar{x} = 76.2, \quad \bar{y} = 168\,548.8, \quad \sum (x - \bar{x})(y - \bar{y}) = 4\,722\,306.2, \quad \sum (x - \bar{x})^2 = 5\,520.8,$$

$$\theta_1^* \approx 855.37\ (\text{HKD/m}^2), \qquad \theta_0^* \approx 103\,369.9\ (\text{HKD}).$$

解释：面积每增加 $1\,\mathrm{m}^2$，租金平均增加约 855 港元。预测 $100\,\mathrm{m}^2$ 的公寓：

$$\hat{y} = 855.37 \times 100 + 103\,369.9 \approx 188\,907 \text{ HKD},$$

预测 $60\,\mathrm{m}^2$：$\hat{y} \approx 154\,692$ HKD。拟合优度 $R^2 = 1 - \mathrm{SSE}/\mathrm{SST} \approx 0.972$，说明面积解释了约 97% 的租金变化。

1.5　多元情形：解析解与凸性

优化问题的标准写法。　如何为多元线性回归 $\hat{f}_\Theta(X) = X\Theta$ 找最优 Θ？通常写成优化问题：

$$\arg\min_x g(x) \quad \text{s.t. 约束条件}, \qquad \hat{\Theta} = \Theta^* = \arg\min_\Theta J(\Theta).$$

为什么选 RSS 作为目标函数？　因为 **RSS 是凸函数**：局部最小值 = 全局最小值。对于凸的可微函数：

$$J(\Theta^*) \text{ 是全局最小} \iff J'(\Theta^*) = 0 \text{ 且 } J''(\Theta^*) > 0.$$

解析解（normal equation）。　记 $J(\Theta) = \|X\Theta - Y\|_2^2$，展开：

$$J(\Theta) = (X\Theta - Y)^\top (X\Theta - Y) = \Theta^\top X^\top X\Theta - Y^\top X\Theta - \Theta^\top X^\top Y + Y^\top Y.$$

对 Θ 求梯度（标量对向量求导，见文末小注）：

$$\frac{\partial J(\Theta)}{\partial \Theta} = 2X^\top X\Theta - X^\top Y - X^\top Y = 2X^\top (X\Theta - Y) \overset{!}{=} 0, \qquad \frac{\partial^2 J(\Theta)}{\partial \Theta^2} = 2X^\top X \text{ (半正定)}.$$

由梯度为零得到**正规方程**（normal equations）：

$$X^\top X\Theta = X^\top Y \;\Rightarrow\; \boxed{\hat{\Theta} = (X^\top X)^{-1} X^\top Y}$$

（前提是 $X^\top X$ 可逆，见 §1.6。）

例题 1.4　补充例：二元特征，四个点正好落在平面上

特征为 2 维，数据（含全 1 列后的 X）与标签：

$$X = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \\ 1 & 1 & 1 \end{pmatrix}, \qquad y = \begin{pmatrix} 1 \\ 4 \\ 3 \\ 6 \end{pmatrix}.$$

手算正规方程：

$$X^\top X = \begin{pmatrix} 4 & 2 & 2 \\ 2 & 2 & 1 \\ 2 & 1 & 2 \end{pmatrix}, \qquad X^\top y = \begin{pmatrix} 14 \\ 9 \\ 10 \end{pmatrix}.$$

解这个 3×3 线性方程组得

$$\hat{\Theta} = (1,\ 2,\ 3)^\top, \qquad \hat{y} = (1, 4, 3, 6)^\top = y.$$

残差为零——四个点恰好可以被平面 $y = 1 + 2x_1 + 3x_2$ 完美拟合（因为 4 个点、3 个参数且几何位置不退化）。

例题 1.5　补充例：两个相关系数的手算对比（体会正规方程的“机器感”）

用一元公式与用矩阵公式算同一组数据，结果应完全一致。取 $x=(-1,0,1)$，$y=(1,2,4)$（因为 $\bar{x}=0$，公式更干净）：

$$S_{xx}=\sum x^2=2,\qquad S_{xy}=\sum xy=(-1)(1)+0+1\cdot 4=3\ \Rightarrow\ \theta_1=\frac{3}{2},\ \theta_0=\bar{y}-\theta_1\bar{x}=\frac{7}{3}.$$

矩阵法：$X=\begin{pmatrix}1&-1\\1&0\\1&1\end{pmatrix}$，$X^\top X=\begin{pmatrix}3&0\\0&2\end{pmatrix}$，$X^\top y=\begin{pmatrix}7\\3\end{pmatrix}$，解 $\begin{pmatrix}3&0\\0&2\end{pmatrix}\Theta=\begin{pmatrix}7\\3\end{pmatrix}$ 得 $\Theta=(7/3,\ 3/2)^\top$——完全一致。（$\bar{x}=0$ 时 $X^\top X$ 呈对角形，两个参数解耦，这也是“中心化”的好处。）

1.6　深入理解一：$X^\top X$ 何时可逆？

解析解 $\hat{\Theta}=(X^\top X)^{-1}X^\top Y$ 要求 $X^\top X$ 可逆。什么条件能保证这一点？

定理

$X^\top X$ 可逆 $\iff$ X 的列向量线性无关。

证明思路。$X\in\mathbb{R}^{m\times(n+1)}$，故 $X^\top X\in\mathbb{R}^{(n+1)\times(n+1)}$ 是方阵。列线性无关 $\iff$ 零空间只含零向量，即 $N(X)=\{0\}$。我们证明 $X^\top X$ 与 X 有相同的零空间：

1. **先证** $N(X)\subset N(X^\top X)$：对任意 $v\in N(X)$，有 $Xv=0$，则 $X^\top Xv=X^\top 0=0$，故 $v\in N(X^\top X)$。
2. **再证** $N(X^\top X)\subset N(X)$：对任意 $v\in N(X^\top X)$，有 $X^\top Xv=0$。两边左乘 $v^\top$：$v^\top X^\top Xv=0\Rightarrow(Xv)^\top(Xv)=0\Rightarrow\|Xv\|_2^2=0\Rightarrow Xv=0$，故 $v\in N(X)$。
3. 两个包含关系合并：$N(X^\top X)=N(X)$。于是 X 列无关时 $N(X^\top X)=\{0\}$，方阵 $X^\top X$ 可逆。

结论：需要“高瘦”的数据矩阵

$X\in\mathbb{R}^{m\times(n+1)}$，若 $\operatorname{rank}(X)=n+1$，则 $X^\top X$ 可逆。这意味着 X 必须是“高瘦”矩阵：$m\geq n+1$。**直观解释：要用 n 个特征做线性回归，至少需要 $n+1$ 个线性无关的训练样本。**

例题 1.6　补充例：什么时候会不可逆？

$n=1$（一列特征 + 全 1 列），两个样本恰好重复：$x^{(1)}=x^{(2)}=2$。此时

$$X=\begin{pmatrix}1&2\\1&2\end{pmatrix},\qquad X^\top X=\begin{pmatrix}2&4\\4&8\end{pmatrix},\qquad \det(X^\top X)=16-16=0.$$

列向量 $(1,1)^\top$ 与 $(2,2)^\top$ 线性相关，$X^\top X$ 奇异。现实含义：同一位置的两个样本无法提供两个独立约束，无穷多组 (θ_0,θ_1) 给出相同的残差和。解决办法：删除冗余特征/样本，或用**岭回归**（见 §1.9）：$X^\top X+\lambda I$ 恒可逆。

1.7　深入理解二：子空间投影视角

换一个完全几何的角度看线性回归。

线性方程组 $Y=X\Theta$（$Y\in\mathbb{R}^m$，$X\in\mathbb{R}^{m\times(n+1)}$，$\Theta\in\mathbb{R}^{n+1}$）：

- 有解 $\iff$ Y 落在 X 的列向量张成的子空间 S 内（即 Y 是特征的某个线性组合）；
- 一般情形（样本有噪声）Y 不在 S 内，方程组无解。

无解时退而求其次：在 S 中找离 Y 最近的向量（Y 在 S 上的*投影*）：

$$\exists\hat{\Theta},\qquad \hat{\Theta}=\arg\min_{\Theta}\left\|X\hat{\Theta}-Y\right\|_2,\qquad \hat{Y}=X\hat{\Theta}.$$

一维简单情形（2 维空间）。 解 $Y=X\theta_1$（Y,X 是 $\mathbb{R}^m$ 中的向量）：有唯一解 $\iff$ Y 与 X 平行。若不平行，则找与 X 平行、且离 Y 最近的向量 $\hat{Y}$。在 2 维欧氏空间中，$\left\|\hat{Y}-Y\right\|_2$ 最小时 $\hat{Y}-Y$ *垂直于* X，即正交投影：

$$\hat{Y}=\frac{X^\top Y}{X^\top X}X,\qquad \hat{\theta}_1=\frac{X^\top Y}{X^\top X}.$$

一般情形。 $\left\|\hat{Y}-Y\right\|_2$ 最小时 $\hat{Y}-Y$ 垂直于整个子空间 S；“垂直于 S” $\iff$ 垂直于 X 的所有列 $\iff$ $X^\top v=0$。于是

$$X^\top(\hat{Y}-Y)=0\ \Rightarrow\ X^\top(X\hat{\Theta}-Y)=0\ \Rightarrow\ X^\top X\hat{\Theta}=X^\top Y\ \Rightarrow\ \hat{\Theta}=(X^\top X)^{-1}X^\top Y.$$

与“求导置零”殊途同归——两条完全不同的路线（优化视角 vs. 几何视角）得到同一个公式。

例题 1.7　补充例：二维投影，数字全对上

$X=(1,1)^\top$，$Y=(2,3)^\top$。最小二乘：

$$\hat{\theta}=\frac{X^\top Y}{X^\top X}=\frac{2+3}{1+1}=2.5,\qquad \hat{Y}=(2.5,\ 2.5)^\top,\qquad \hat{Y}-Y=(-0.5,\ 0.5)^\top.$$

验证正交性：$X^\top(\hat{Y}-Y)=1\times(-0.5)+1\times 0.5=0$。$\hat{Y}$ 就是 Y 在第一象限对角线上的正交投影。

1.8　偏差–方差权衡与过拟合

数据为什么不可能被完美拟合？ 真实关系可写成

$$y=f(X)+\epsilon,\qquad \mathbb{E}(\epsilon)=0,\quad \mathrm{Var}(\epsilon)=\sigma^2,$$

ϵ 是观测噪声。对任意固定 X（标签 y），期望预测误差可分解为

$$\boxed{\mathrm{EPE}(X)=\mathbb{E}\big[(y-\hat{f}(X))^2\big]=\underbrace{\mathrm{Bias}\big(\hat{f}(X)\big)^2}_{\text{偏差}^2}+\underbrace{\mathrm{Var}\left(\hat{f}(X)\right)}_{\text{方差}}+\underbrace{\sigma^2}_{\text{不可约误差}}}\tag{6}$$

其中

$$\mathrm{Bias}\big(\hat{f}(X)\big)=\mathbb{E}\big[\hat{f}(X)\big]-f(X),\qquad \mathrm{Var}\left(\hat{f}(X)\right)=\mathbb{E}\Big[\big(\hat{f}(X)-\mathbb{E}[\hat{f}(X)]\big)^2\Big].$$

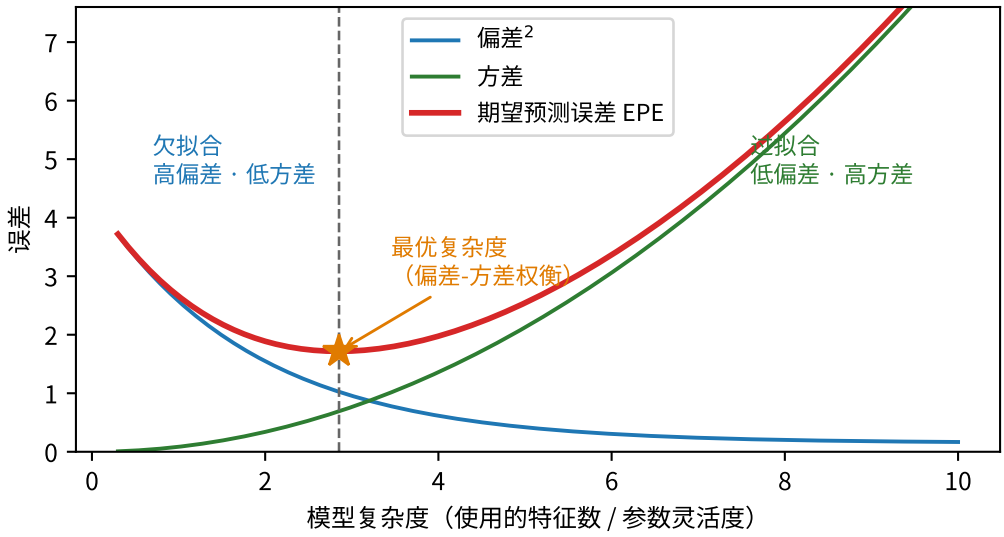


图 2: 偏差 ^{2}、方差与总误差随模型复杂度的变化：最优复杂度在两者交叉点附近。

权衡（tradeoff）。　想象对“随机重采样”得到的不同训练集反复训练：

1. 若模型每次都*完美拟合*训练数据：偏差很低，但换一批数据模型就大变样——**方差很高（过拟合**，模型复杂度太高）；
2. 若模型是常数（无视数据）：方差为零，但显然偏差很高（**欠拟合**，模型复杂度太低）。

“模型复杂度”常指使用的特征数量。低偏差高方差 $\leftrightarrow$ 过拟合；高偏差低方差 $\leftrightarrow$ 欠拟合。目标不是分别最小化偏差和方差，而是最小化它们的**总和**。

为什么普通最小二乘需要“补救”？

OLS 倾向于学出**低偏差、高方差**的模型（对训练数据拟合非常激进）。有时故意牺牲一点偏差来换取方差的大幅下降，总 EPE 反而更小——这正是收缩方法的动机。

1.9　收缩方法：岭回归与 Lasso

收缩方法（shrinkage methods）是一类自动调节模型复杂度的方法，代表：岭回归（Ridge）与 Lasso。

岭回归（Ridge regression）。　在 OLS 的损失上加一个对参数*平方大小*的惩罚：

$$\hat{\Theta}_{\text{ridge}} = \arg\min_{\Theta} \ \|X\Theta + \theta_0 - Y\|_2^2 + \lambda \|\Theta\|_2^2, \qquad \|\Theta\|_2^2 = \sum_{i=1}^{n} \theta_i^2. \tag{7}$$

注意：

- 惩罚项中**不包含** θ_0（只收缩特征系数）；
- λ 是人工设定的**超参数**：$\lambda = 0$ 退化为 OLS；λ 越大，收缩越强；
- 对中心化数据可推出闭式解 $\hat{\theta}_j^{\text{ridge}} = \hat{\theta}_j^{\text{OLS}}/(1+\lambda)$（单变量情形），即所有系数被*一致压向零*（但通常压不到零）。

惩罚项在解决什么问题?

当特征之间存在**相关性**时，OLS 的系数会变得“不稳定”：一个很大的正系数可以被一个同样大的负系数抵消（两个相关特征各说各话），系数方差很大。惩罚大系数后，优化器倾向于把系数压小，这种“互相抵消的极端解”被抑制，预测更稳定。神经网络里对权重做 L2 惩罚的做法（weight decay）与岭回归同理。

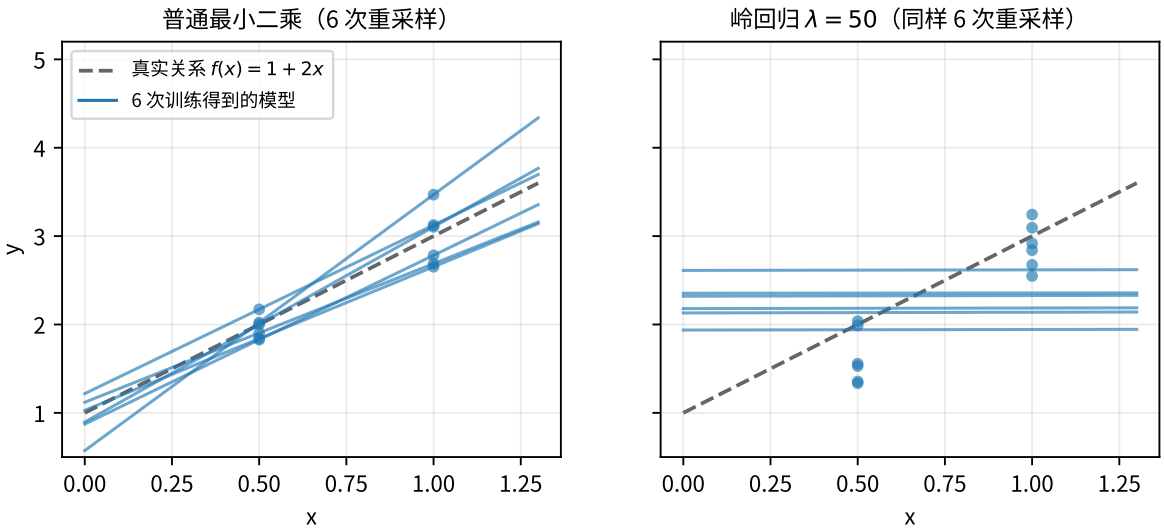


图 3: 左：OLS 在 6 次随机重采样上的拟合线（方差大）；右：岭回归（$\lambda = 50$）在同样数据上（更稳但训练拟合变差）。

例题 1.8　补充例：手算一次“收缩”的效果

中心化数据 $x_c = (-1, 0, 1)$，$y_c = (1, 2, 3)$（中心化后 $\bar{x} = \bar{y} = 0$，无截距项）。

$$S_{xx} = \sum x_c^2 = 2, \quad S_{xy} = \sum x_c y_c = 2 \;\Rightarrow\; \theta_1^{\text{OLS}} = \frac{2}{2} = 1.$$

岭回归闭式解（单变量）：

$$\theta_1^{\text{ridge}} = \frac{S_{xy}}{S_{xx} + \lambda}: \qquad \lambda = 1 \;\Rightarrow\; \frac{2}{3} \approx 0.667, \qquad \lambda = 2 \;\Rightarrow\; \frac{2}{4} = 0.5.$$

对比三种模型对 $x = 1$（即 $x_c = 1$）的预测：OLS 给 1.0，$\lambda = 1$ 给 0.667，$\lambda = 2$ 给 0.5。λ 越大，系数越靠近 0、预测越“保守”——这就是“以偏差换方差”。

Lasso 回归。　与岭回归几乎相同，只把惩罚换成 **L1 范数**：

$$\hat{\Theta}_{\text{lasso}} = \arg\min_{\Theta} \; \|X\Theta + \theta_0 - Y\|_2^2 + \lambda \|\Theta\|_1, \qquad \|\Theta\|_1 = \sum_{i=1}^{n} |\theta_i|. \tag{8}$$

L1 范数衡量参数的**稀疏性**：稀疏 = 参数中很多元素为 0。若 Θ 中大量元素接近 0，实际用到的特征就少，模型复杂度自然下降。Lasso 与岭回归的几何差别（L1 球的“角”使解可以正好落在坐标轴上）使得 **Lasso 可以把系数精确压到 0**，从而顺带完成特征选择；岭回归一般只把系数压小而不压没。

讲义实验：同一实验下的三种模型

讲义在 $X = 0.5$ 与 $X = 1.0$ 两个位置加噪采样，重复训练 6 次：OLS 每次都能贴合训练点，但 6 条线差异巨大；岭回归/Lasso 的 6 条线明显更集中，但对训练点的拟合变差。**结论：收缩把“波动”换成了“稳健”**。图 3 复现了这个实验。

1.10 本章小结

线性回归一页总结

- **模型**：$\hat{Y} = X\Theta$（全 1 列吸收偏置）；
- **损失**：RSS $J(\Theta) = \|X\Theta - Y\|_2^2$，凸函数；
- **解析解**：$\hat{\Theta} = (X^\top X)^{-1} X^\top Y$（需 X 列满秩，$m \geq n+1$）；
- **几何**：$\hat{Y}$ 是 Y 在特征列空间上的正交投影；正规方程源自 $X^\top(\hat{Y} - Y) = 0$；
- **权衡**：EPE = 偏差 ^{2} + 方差 + σ^2；OLS 低偏差高方差；
- **收缩**：Ridge 惩罚 $\|\Theta\|_2^2$；Lasso 惩罚 $\|\Theta\|_1$（可稀疏化）。

对应讲义与阅读。 Lecture 2 全部内容；*The Elements of Statistical Learning* (2nd ed.) 第 3.1, 3.2, 3.4, 2.9 节；*Introduction to Linear Algebra* (Strang, 5th ed.) 第 4.2, 4.3 节（子空间与投影）。

自检题（线性回归）

1. 数据 $(0,1),(1,2),(2,2)$，用最小二乘求 $\hat{y} = \theta_1 x + \theta_0$。
2. 续前题：若改用岭回归且只有一个特征（中心化数据 $x_c = (-1,0,1)$、$y_c = (1,2,3)$），$\lambda = 2$ 时 θ_1 是多少？预测 $x = 1$ 的值是多少？
3. 什么情况下 $X^\top X$ 不可逆？举一个具体的失败数据例子（$n = 1$）。
4. 用一句话解释：为什么 EPE 中“偏差”和“方差”不能同时随便最小化？

答案

1. $\bar{x} = 1, \bar{y} = 5/3$；$S_{xy} = -\frac{2}{3} + 0 + \frac{1}{3} = 1$，$S_{xx} = 2$，$\theta_1 = \frac{1}{2}$，$\theta_0 = \frac{5}{3} - \frac{1}{2} = \frac{7}{6}$。即 $\hat{y} = \frac{1}{2}x + \frac{7}{6}$。
2. 岭解 $\theta_1 = \frac{S_{xy}}{S_{xx}+\lambda} = \frac{2}{2+2} = 0.5$；在 $x = 1$ 预测 $\hat{y}_c = 0.5$。
3. X 的列线性相关时，例如两个样本的 x 完全相同（$x^{(1)} = x^{(2)} = 2$），$X = \begin{pmatrix} 1 & 2 \\ 1 & 2 \end{pmatrix}$，$X^\top X = \begin{pmatrix} 2 & 4 \\ 4 & 8 \end{pmatrix}$ 奇异（行列式为 0）。
4. 因为二者通常此消彼长：把模型调复杂（追求低偏差）会放大方差，把模型调简单（压低方差）会抬高偏差；最优策略是让二者之和（加上不可约的 σ^2）最小。

2 逻辑回归（Lecture 3）

本章学习目标

- 理解**分类**问题与回归问题的区别（离散 vs. 连续输出）；
- 理解为什么线性回归 + 硬阈值不适合分类（对离群点敏感）；
- 掌握 **odds（几率）→ logit 变换 → sigmoid 函数**这条推导链；
- 写出逻辑回归模型 $P(\hat{y}=1|X)=\sigma(X^\top\Theta)$，并解释其决策边界是超平面；
- 理解**监督准则 → 似然函数 → 交叉熵**的转化，能独立推导梯度；
- 理解**梯度下降**的原理（方向导数 + Cauchy–Schwarz）、算法与失效情形；
- 了解交叉熵凸性的完整证明（Hessian 半正定）。

2.1 分类问题

三个典型场景。

- **垃圾邮件检测**：自动判断邮件是 spam 还是 normal；
- **图像分类**：识别图片里是猫、狗还是船；
- **癌症诊断**：医学图像判断恶性肿瘤还是良性病变。

什么是分类? 分类是一个把想法与对象进行识别、区分、理解的过程。目标：给定一批带有类别标签的样本，学习一个分类器，使它能够自动识别同类集合中的新样本。

分类 vs. 回归

分类的输出是**离散值**（类别标签）；回归的输出是**连续值**。这是两者最根本的区别。

记号。 m 个训练样本，每个是 n 维特征向量，标签为 $y^{(1)},\dots,y^{(m)}$：

$$X^{(1)}=(x_1^{(1)},\dots,x_n^{(1)}),\ \dots,\ X^{(m)}=(x_1^{(m)},\dots,x_n^{(m)}).$$

二分类 vs. 多分类。

- **二分类**：只有两个类别，通常用 $0,1$ 标记（0 负类、1 正类）。例：邮件是否 spam（0）；照片里有没有猫（0/1）；你能不能进 CUHK。
- **多分类**：多于两个类别，用 $1,2,3,\dots$ 标记。例：照片里是猫/狗/猪/鸭；学生属于书院（S.H. Ho、New Asia、Chung Chi、Morningside…）。

本讲只处理二分类；多分类可由“一对多”（one-vs-rest）等策略组合二分类器得到。

决策边界与线性分类器。 分类的直观图像：把整个特征空间划分成若干区域，每个区域对应一个类别。划分区域的曲线/曲面称为**决策边界**（decision boundary）。

线性分类器：只根据特征的*线性组合*分类，其决策边界是直线/超平面的并集。对二分类，一条直线（高维时为一个超平面）把特征空间分成两个半空间，各属一类。

2.2　从线性回归到逻辑回归

线性回归能直接做分类吗？　设 $y \in \{0,1\}$，想要 $\hat{f}(X)$ 直接预测 $P(\hat{y}=1|X)$。问题一：线性函数的取值范围是 $(-\infty,+\infty)$，无法天然充当概率。补救方案：加“硬阈值”规则——$\hat{f}(X) \geq 0.5$ 判 1，否则判 0。问题二（致命）：硬阈值对**离群点**极其敏感。少量位置离谱的点会把拟合直线拽歪，导致整条决策边界平移，分类结果大面积出错。

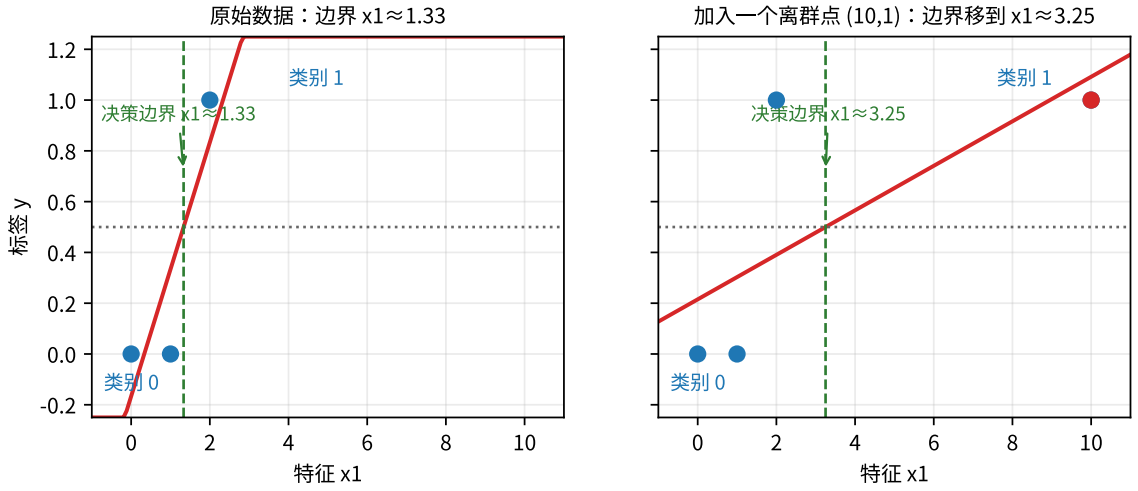


图 4: 线性回归 + 阈值做分类：左图原始 3 点，边界 $x_1 \approx 1.33$；右图加入一个离群点 $(10,1)$ 后，边界被拽到 $x_1 \approx 3.25$，原区域的分类大面积失效。

例题 2.1　补充例：离群点如何拽动决策边界（配合图 4）

数据 $(0,0),(1,0),(2,1)$，先用线性回归拟合再取 0.5 为界：

$$\bar{x}=1,\ \bar{y}=\tfrac{1}{3},\quad S_{xy}=(-1)(-\tfrac{1}{3})+0\cdot(-\tfrac{1}{3})+1\cdot\tfrac{2}{3}=1,\quad S_{xx}=2,$$

$$\theta_1=0.5,\quad \theta_0=\tfrac{1}{3}-0.5=\tfrac{-1}{6};\qquad \text{边界：}\ 0.5x-\tfrac{1}{6}=0.5\ \Rightarrow\ x\approx 1.33.$$

现在把 $(10,1)$ 也加进去：$\bar{x}=3.25,\ \bar{y}=0.5,\ S_{xy}=5.5,\ S_{xx}=62.75$，

$$\theta_1=\frac{5.5}{62.75}\approx 0.0876,\qquad \theta_0=0.5-0.0876\times 3.25\approx 0.2151;$$

边界移到

$$x=\frac{0.5-\theta_0}{\theta_1}=\frac{0.2849}{0.0876}\approx 3.25.$$

仅仅一个离群点，就把边界从 $x\approx 1.33$ 拽到了 $x\approx 3.25$——原来 $x=2.5$ 的样本本来是 1 类，现在会被误判为 0 类。这就是“硬阈值 + 线性回归”不可用的原因。

寻找更好的变换：从 odds 出发。　我们要把 $(-\infty,+\infty)$ 的输出“压”进 $(0,1)$。先看**几率**（odds）：事件 A 发生概率 $P(A)=p$，则

$$\text{odds}(p)=\frac{p}{1-p}\quad\text{（事件概率与互补事件概率之比）.}\tag{9}$$

例题 2.2　补充例：三个 odds 计算（讲义示例）

- 掷硬币正面概率 0.5：$\text{odds} = \frac{0.5}{1-0.5} = 1$（1 比 1）；
- 湖人夺冠概率 0.75：$\text{odds} = \frac{0.75}{0.25} = 3$（3 比 1）；
- 论文被 CVPR 接收概率 0.25：$\text{odds} = \frac{0.25}{0.75} = \frac{1}{3}$（1 比 3）。

反过来：若 $\text{odds} = 4$，则 $p = \frac{\text{odds}}{1+\text{odds}} = \frac{4}{5} = 0.8$；若 $\text{odds} = 9$，则 $p = 0.9$。

logit 变换。　odds 的范围是 $(0, +\infty)$，还是不够对称、范围不够“宽”。取对数得到 **logit（对数几率）**：

$$\text{logit}(p) = \ln \text{odds}(p) = \ln\left(\frac{p}{1-p}\right), \qquad \text{范围}(-\infty, +\infty). \tag{10}$$

logit 把概率 $(0, 1)$ 映射到整个实数轴；反过来，logit^{-1} 把任何实数映射回概率。

求 logit^{-1}（重要推导）。　logit 严格单调递增，故反函数存在。设 $z = \text{logit}(p)$：

$$z = \ln\frac{p}{1-p} \;\Rightarrow\; e^z = \frac{p}{1-p} \;\Rightarrow\; p = e^z(1-p) \;\Rightarrow\; p(1+e^z) = e^z$$

$$p = \frac{e^z}{1+e^z} = \frac{1}{1+e^{-z}} \quad\Longrightarrow\quad \boxed{\text{logit}^{-1}(z) = \frac{1}{1+e^{-z}}}$$

（其中第二步乘负号取倒数也可得 $e^{-z} = \frac{1-p}{p}$，两法等价。）

2.3　逻辑回归模型

把线性函数与 logit^{-1} 复合：

$$\boxed{P(\hat{y}=1|X) = \text{logit}^{-1}(X^\top\Theta + \theta_0) = \frac{1}{1+e^{-(X^\top\Theta+\theta_0)}} = \sigma(X^\top\Theta + \theta_0)} \tag{11}$$

这就是逻辑回归的基本形式。$\sigma(\cdot)$ 称为**逻辑 sigmoid 函数**，图像是“S”形。

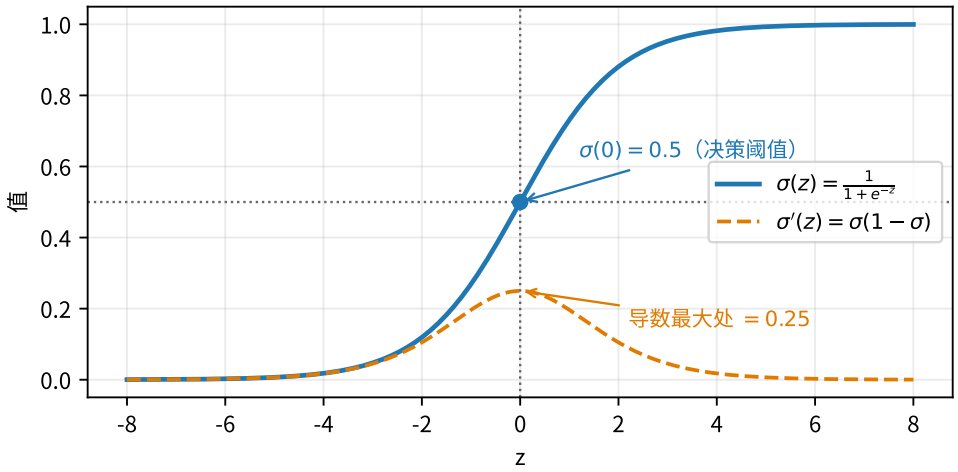


图 5: sigmoid 函数及其导数：$\sigma(0) = 0.5$，$\lim_{z\to+\infty}\sigma(z) = 1$，$\lim_{z\to-\infty}\sigma(z) = 0$；导数在 0 处最大 (0.25)，到处光滑。

关键性质（务必记住）：

- $\sigma(0)=0.5$；$z\to+\infty$ 时趋近 1；$z\to-\infty$ 时趋近 0；
- **单调递增**，一阶导数呈钟形；（补充：$\sigma'(z)=\sigma(z)\big(1-\sigma(z)\big)\in(0,0.25]$，推导见 §2.5）
- 同样把 θ_0 吸收进 Θ：$P(\hat{y}=1|X)=\sigma(X^\top\Theta)$，$\Theta\in\mathbb{R}^{n+1}$、$X$ 含全 1 列。

分类规则。 由 $P(\hat{y}=1|X)\geq P(\hat{y}=0|X)$（等价地 ≥ 0.5）时判 $\hat{y}=1$，否则判 0。注意 $\sigma(z)\geq 0.5\iff z\geq 0$，所以：

$$X^\top\Theta\geq 0\ \Rightarrow\ \hat{y}=1;\qquad X^\top\Theta<0\ \Rightarrow\ \hat{y}=0.$$

决策边界就是超平面 $z=X^\top\Theta=0$——逻辑回归本质上仍是一个（广义）线性分类器，sigmoid 只负责把距离“翻译”成概率，不改变边界的几何形状。距边界越远，概率越接近 0/1，置信度越高。

逻辑回归的三个优点

1. 直接输出条件概率 $P(y=1|X)$，可解释性强；
2. 概率在 $X^\top\Theta=0$ 附近变化剧烈，恰好是最需要区分样本的区域；
3. 相比“线性回归 + 硬阈值”，对离群点更稳健（sigmoid 两侧饱和，单个远处点对损失影响有界）。

例题 2.3　补充例：手算几个 sigmoid 输出

$$\sigma(0)=0.5,\quad \sigma(1)=\frac{1}{1+e^{-1}}\approx 0.731,\quad \sigma(2)\approx 0.881,\quad \sigma(3)\approx 0.953,$$
$$\sigma(-1)\approx 0.269,\quad \sigma(-2)\approx 0.119,\quad \sigma(-3)\approx 0.047.$$

观察：一个样本的 $X^\top\Theta=2$，就给出“88% 是正类”的概率判断；若 $X^\top\Theta=-2$，则只有 11.9% 概率为正类。

2.4　优化：从监督准则到交叉熵

监督准则。 对每个样本 $X^{(i)}$，模型给出 $P(\hat{y}^{(i)}=1|X^{(i)})=\sigma(X^{(i)\top}\Theta)$（关于 Θ 的函数）。学习目标：

- 若 $y^{(i)}=1$：希望预测概率尽量接近 1；
- 若 $y^{(i)}=0$：希望预测概率尽量接近 0（即 $1-P$ 接近 1）。

把两句话统一写成**预测正确的概率**：

$$p_i\overset{\text{def}}{=}P(\hat{y}^{(i)}=1|X^{(i)})^{\,y^{(i)}}\cdot\Big(1-P(\hat{y}^{(i)}=1|X^{(i)})\Big)^{\,1-y^{(i)}}.\tag{12}$$

验证：$y^{(i)}=0$ 时 $p_i=P(\hat{y}=0|X^{(i)})$；$y^{(i)}=1$ 时 $p_i=P(\hat{y}=1|X^{(i)})$。无论属于哪类，p_i 都表示“预测与真实标签一致的概率”。

似然函数。 假设样本相互独立，所有样本同时预测正确的**联合概率**为

$$p(\Theta)=\prod_{i=1}^{m}p_i=\prod_{i=1}^{m}P(\hat{y}^{(i)}=1|X^{(i)})^{y^{(i)}}\Big(1-P(\hat{y}^{(i)}=1|X^{(i)})\Big)^{1-y^{(i)}}.\tag{13}$$

$p(\Theta)$ 称为关于 Θ 的**似然函数**（likelihood）。通过最大化似然函数估计概率模型参数的方法称为**最大似然估计**（MLE）。

取负对数：从乘积到求和。　最大化 $p(\Theta)$ 等价于最小化 $-\ln p(\Theta)$（对数单调递增；且乘积取对数变求和，求导方便）：

$$E(\Theta) = -\ln p(\Theta) = -\ln \prod_{i=1}^{m} p_i = -\sum_{i=1}^{m} \ln p_i$$

$$= -\sum_{i=1}^{m} \Big[y^{(i)} \ln P(\hat{y}^{(i)} = 1 | X^{(i)}) + (1 - y^{(i)}) \ln \Big(1 - P(\hat{y}^{(i)} = 1 | X^{(i)}) \Big) \Big] = \sum_{i=1}^{m} E_i(\Theta),$$

其中单样本损失

$$E_i(\Theta) = -y^{(i)} \ln P(\hat{y}^{(i)} = 1 | X^{(i)}) - (1 - y^{(i)}) \ln \Big(1 - P(\hat{y}^{(i)} = 1 | X^{(i)}) \Big). \tag{14}$$

每个 $E_i(\Theta)$ 正是**交叉熵误差**（cross-entropy error）函数：

$$\text{cross-entropy error} = -y \ln P(y) - (1 - y) \ln(1 - P(y)), \qquad y \in \{0, 1\}.$$

例题 2.4　补充例：交叉熵到底在惩罚什么

记 $g = P(\hat{y} = 1 | X)$。

- 样本 $y = 1$：损失 $= -\ln g$。若 $g = 1$（完全自信且正确），损失 $= 0$；若 $g = 0.5$，损失 $= \ln 2 \approx 0.693$；$g \to 0$（自信且错）时损失 $\to +\infty$——**错得越自信，罚得越狠**。
- 样本 $y = 0$：损失 $= -\ln(1 - g)$。$g = 0.15$ 时损失 $= -\ln 0.85 \approx 0.163$；$g = 0.9$ 时损失 $= -\ln 0.1 \approx 2.30$。

注意：单样本 $E_i(\Theta)$ 对某个样本的曲线（横轴取 $X^{(i)\top}\Theta$）总是“下凸”的——这正是下一节凸性讨论的动机。

2.5　深入理解：交叉熵损失为什么是凸的

回顾凸性定义：$f : \mathbb{R}^n \to \mathbb{R}$ 凸 $\iff$ 对任意 Θ_1, Θ_2、$0 \le t \le 1$：

$$f(t\Theta_1 + (1 - t)\Theta_2) \le t f(\Theta_1) + (1 - t) f(\Theta_2).$$

可微一元函数凸 $\iff$ 二阶导非负；多元可微函数凸 $\iff$ Hessian 矩阵处处半正定（$\succeq 0$）。凸函数的性质：局部最小 = 全局最小。

证明 $E_i(\Theta)$ 凸（讲义补充推导，步骤编号与讲义一致）。　记记 $g_i(\Theta) = P(\hat{y}^{(i)} = 1 | X^{(i)}) = \frac{1}{1 + e^{-X^{(i)\top}\Theta}} \in (0, 1)$，则

$$E_i(\Theta) = -y^{(i)} \ln g_i(\Theta) - (1 - y^{(i)}) \ln \big(1 - g_i(\Theta) \big).$$

第一步： $\frac{\partial E_i}{\partial g_i}$。

$$\frac{\partial E_i}{\partial g_i} = -\frac{y^{(i)}}{g_i} + (1 - y^{(i)}) \frac{1}{1 - g_i} = \frac{-y^{(i)}(1 - g_i) + (1 - y^{(i)}) g_i}{g_i(1 - g_i)} = \frac{g_i - y^{(i)}}{g_i(1 - g_i)}.$$

第二步： $\frac{\partial g_i}{\partial \Theta}$（对 $z = X^{(i)\top}\Theta$ 用链式法则，$\frac{d\sigma(z)}{dz} = \sigma(z)(1 - \sigma(z))$）：

$$\frac{\partial g_i(\Theta)}{\partial \Theta} = g_i(\Theta) \big(1 - g_i(\Theta) \big) X^{(i)}.$$

第三步：一阶导（合并前两步）。

$$\frac{\partial E_i(\Theta)}{\partial \Theta} = \frac{\partial E_i}{\partial g_i} \cdot \frac{\partial g_i}{\partial \Theta} = \frac{g_i - y^{(i)}}{g_i(1-g_i)} \cdot g_i(1-g_i)X^{(i)} = \big(g_i(\Theta) - y^{(i)}\big)X^{(i)}.$$

（这个式子非常漂亮：*梯度 = 预测概率减真实标签，乘以样本向量。*）

第四步：二阶导（Hessian）。

$$\frac{\partial^2 E_i(\Theta)}{\partial \Theta^2} = \frac{\partial}{\partial \Theta}\Big[\big(g_i(\Theta) - y^{(i)}\big)X^{(i)}\Big] = X^{(i)} \cdot \frac{\partial g_i(\Theta)}{\partial \Theta} = g_i(\Theta)\big(1 - g_i(\Theta)\big)\, X^{(i)}X^{(i)\top}.$$

第五步：验证半正定。对任意 v：

$$v^\top \Big[g_i(1-g_i)\, X^{(i)}X^{(i)\top}\Big]v = \underbrace{g_i(1-g_i)}_{>0}\underbrace{(X^{(i)\top}v)^\top(X^{(i)\top}v)}_{\geq 0} = g_i(1-g_i)\, \Big\|X^{(i)\top}v\Big\|_2^2 \geq 0.$$

所以 $H \succeq 0$，E_i 凸。又因“凸函数之和仍凸”（两凸函数逐项相加直接套定义即得），$E(\Theta) = \sum_i E_i(\Theta)$ 也是凸的。

例题 2.5　补充例：单变量“手算”版凸性直觉

固定一个样本、只看 $z = X^\top\Theta$ 这一维。令 $g = \sigma(z)$，单样本损失 $h(z) = -\ln\sigma(z)$（取 $y = 1$）。由链式法则：

$$h'(z) = -\frac{\sigma'(z)}{\sigma(z)} = -\big(1 - \sigma(z)\big) = \sigma(z) - 1 < 0$$

（损失单调下降，越“分对”损失越小）；

$$h''(z) = \sigma'(z) = \sigma(z)\big(1 - \sigma(z)\big) > 0.$$

二阶导恒正 $\Rightarrow$ h 凸。各样本在这些方向上的凸性叠加，就是 Hessian 半正定的来源。

2.6　优化：梯度下降

为什么不用解析解？　类比 RSS，我们想解 $\frac{\partial E(\Theta)}{\partial \Theta} = 0$：

$$0 = \frac{\partial E(\Theta)}{\partial \Theta} = \sum_{i=1}^{m}\big(g_i(\Theta) - y^{(i)}\big)X^{(i)} = \sum_{i=1}^{m}\left(\frac{1}{1 + e^{-X^{(i)\top}\Theta}} - y^{(i)}\right)X^{(i)}.$$

这是一个关于 Θ 的*非线性*方程组（Θ 藏在 sigmoid 里），**找不到显式解**。退而求其次：用**迭代式优化**——梯度下降。（顺带一提：E 是凸的，所以只要能收敛，一定到全局最优。）

直觉。　把目标函数看成一座山：每步只往*下坡*方向走，且选*最陡*的方向，步步逼近山谷底部。

为什么梯度方向就是最陡方向？（方向导数 + Cauchy–Schwarz）　定义 $g(h) = f(\Theta + hv)$，方向导数

$$D_v f(\Theta) = \lim_{h\to 0}\frac{f(\Theta + hv) - f(\Theta)}{h} = \lim_{h\to 0}\frac{g(h) - g(0)}{h} = g'(0).$$

由链式法则 $g'(h) = \nabla f(\Theta + hv)\cdot v$。因此：

$$D_v f(\Theta) = \nabla f(\Theta)\cdot v.$$

再用 Cauchy–Schwarz 不等式

$$D_v f(\Theta) = \nabla f(\Theta)\cdot v \;\leq\; \|\nabla f(\Theta)\|_2\,\|v\|_2\,,$$

等号当且仅当 v 与 $\nabla f(\Theta)$ 同向。这说明：在所有单位方向中，$\nabla f(\Theta)$ 指向*方向导数最大*（最陡上升）的方向，$-\nabla f(\Theta)$ 即最陡下降方向。

算法。

梯度下降（gradient descent）

输入：学习率 $\alpha > 0$。　**初始化**：$\Theta \leftarrow \Theta_0$（随机）。

$$\text{while 未收敛：} \qquad \Theta \leftarrow \Theta - \alpha \nabla f(\Theta)$$

- α 足够小且 f 可微时，梯度下降保证收敛到*局部*最小；
- 若 f 是凸函数，局部最小 = 全局最小，因此收敛点就是全局最优；
- α 太小 $\to$ 学得很慢；α 太大 $\to$ 震荡甚至发散；α 允许每次迭代调整。

例题 2.6　补充例：在 $f(x,y) = x^2 + y^2$ 上看渐近收敛（讲义图示过程）

取 $\alpha = 0.3$，从 $(-1,-1)$ 出发。每步 $\Theta \leftarrow \Theta - 0.3\nabla f = \Theta - 0.6\Theta = 0.4\Theta$：

$$(-1,-1) \to (-0.4,-0.4) \to (-0.16,-0.16) \to (-0.064,-0.064) \to (-0.0256,-0.0256) \to \cdots$$

函数值依次为 $2,\ 0.32,\ 0.051,\ 0.0082,\ 0.0013,\ldots$ 几何级数式收敛。对比：若取 $\alpha = 0.6$，因子变为 $|1-2\alpha| = |-0.2|$，依然收敛（方向交替）；若 $\alpha > 0.5$ 太多（如 $\alpha = 1.1$，因子 $|1-2.2| = 1.2 > 1$），就会震荡并**发散**。

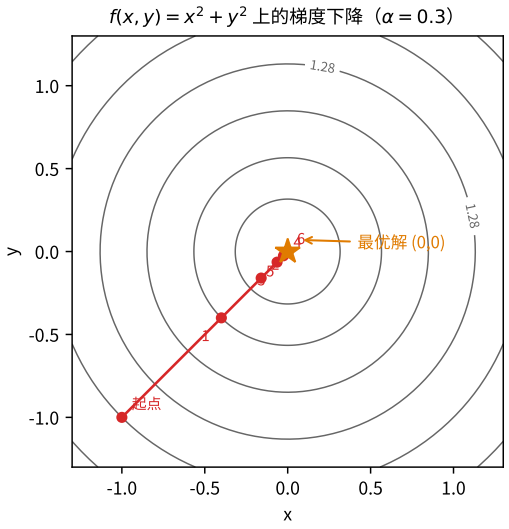


图 6：$f(x,y) = x^2 + y^2$ 上的梯度下降路径（$\alpha = 0.3$，从 $(-1,-1)$ 出发），每步严格向“谷底”缩短。

例题 2.7　讲义 Quiz：数迭代次数

对 $f(\theta) = \theta^2$ 做梯度下降，$\alpha = 0.4$，初值 $\theta_0 = 10$，收敛判据 $|f(\theta^*) - f(\theta)| \le 0.01$。至少需要多少次迭代?

解（选 B：3 次）。$\nabla f(\theta) = 2\theta$，更新式

$$\theta \leftarrow \theta - 0.4 \cdot 2\theta = 0.2\,\theta.$$

$$\theta_0 = 10,\ f = 100; \quad \theta_1 = 2,\ f = 4; \quad \theta_2 = 0.4,\ f = 0.16; \quad \theta_3 = 0.08,\ f = 0.0064.$$

第 3 次迭代后 $|0 - 0.0064| \le 0.01$，故 3 次收敛。

失效情形。　非凸目标：有时能意外找到全局最优，但大多数复杂非凸函数会陷入局部最小，梯度下降无法保证到达全局最优。逻辑回归的交叉熵是凸的，所以这个问题在本讲中不存在。

2.7　逻辑回归的梯度下降

回到逻辑回归。已推得交叉熵目标 $E(\Theta)$ 的梯度（第三步结论对所有样本求和）：

$$\nabla E(\Theta)=\frac{\partial E(\Theta)}{\partial \Theta}=\sum_{i=1}^{m}\left(\frac{1}{1+e^{-X^{(i)\top}\Theta}}-y^{(i)}\right)X^{(i)}=\sum_{i=1}^{m}\left(\sigma(X^{(i)\top}\Theta)-y^{(i)}\right)X^{(i)}. \tag{15}$$

逻辑回归的梯度下降算法

输入：$\alpha>0$。　**初始化**：Θ 随机。

$$\text{while 未收敛：}\qquad \Theta\leftarrow\Theta-\alpha\sum_{i=1}^{m}\left(\sigma\left(X^{(i)\top}\Theta\right)-y^{(i)}\right)X^{(i)}$$

例题 2.8　补充例：两个点、全流程数值演示（可以手算的迷你训练）

数据：$X^{(1)}=(1,1)$，$y^{(1)}=1$；$X^{(2)}=(-1,-1)$，$y^{(2)}=0$（数据关于原点对称，明显可分）。取 $\alpha=0.5$，$\Theta_0=(0,0)^\top$。

第 1 次迭代（按单样本梯度累加）：$\sigma(0)=0.5$，梯度 $=(0.5-1)(1,1)+(0.5-0)(-1,-1)=(-0.5,-0.5)+(-0.5,-0.5)=(-1,-1)$。

$$\Theta_1=(0,0)-0.5\times(-1,-1)=(0.5,0.5).$$

第 2 次迭代：$z_1=X^{(1)\top}\Theta_1=1$，$z_2=-1$，$\sigma(1)=0.731$，$\sigma(-1)=0.269$，

$$\text{梯度}=(0.731-1)(1,1)+(0.269-0)(-1,-1)=(-0.538,-0.538),$$

$$\Theta_2=(0.5,0.5)+0.269=(0.769,0.769).$$

继续下去 Θ 沿 $(1,1)$ 方向持续增大：正样本打分 $z=X^{(1)\top}\Theta=0\to1\to1.54\to1.89\to2.15\to\cdots$，相应概率 $0.5\to0.731\to0.823\to0.869\to0.896\to\cdots$ 逐轮逼近 1（但永远达不到 1）。**观察：即使数据线性可分、没有离群点，逻辑回归的参数也不会“收敛到某组有限值”而是持续变大**——不过分类结果（谁在边界哪一侧）早已稳定。这解释了为什么实践中要设最大迭代次数或加正则。

2.8　本章小结

逻辑回归一页总结

- **模型**：$P(\hat{y}=1|X)=\sigma(X^\top\Theta)$，$\sigma(z)=\frac{1}{1+e^{-z}}$；
- **变换链**：$p\ \to\ \text{odds}=\frac{p}{1-p}\ \to\ \text{logit}=\ln\frac{p}{1-p}\ \to\ \sigma$ 反变换；
- **决策规则**：$X^\top\Theta\geq0$ 判 1——边界是超平面，本质是线性分类器；
- **损失**：负对数似然 = 交叉熵 $E(\Theta)=-\sum_i[y^{(i)}\ln g_i+(1-y^{(i)})\ln(1-g_i)]$，凸；
- **梯度**：$\nabla E=\sum_i(\sigma(X^{(i)\top}\Theta)-y^{(i)})X^{(i)}$，无解析解，用梯度下降；
- **预备知识**：方向导数 + Cauchy–Schwarz 论证“梯度 = 最陡方向”；凸 + 梯度下降 = 全局最优。

对应讲义与阅读。 Lecture 3 全部内容；*Advanced Data Analysis from an Elementary Point of View*（Shalizi）第 12 章；*The Elements of Statistical Learning* (2nd ed.) 第 4.4 节。

自检题（逻辑回归）

1. 某事件概率 $p = 0.8$，odds 与 logit 分别是多少？（用 ln 表示即可）
2. 用一句话说明：为什么逻辑回归的决策边界仍是直线/超平面，但“概率输出”让它比线性回归 + 阈值更稳健？
3. 写出单样本交叉熵损失对 Θ 的梯度表达式，并解释其中每一项的直观含义。
4. 对逻辑回归的损失 $E(\Theta)$，若某样本 $y = 1$ 且当前 $X^\top\Theta = 0$，单样本损失是多少？此时该样本梯度方向是什么？

答案

1. odds $= \frac{0.8}{0.2} = 4$；logit $= \ln 4 \approx 1.386$。
2. 判决只看 σ 的“零点” $X^\top\Theta = 0$，sigmoid 单调且以 0.5 为分界，故边界仍是 $X^\top\Theta = 0$ 这个超平面；但概率随到边界距离平滑变化（而非硬切），远处的离群点被 sigmoid 饱和“压住”，不会无限拽动边界。
3. $\nabla_\Theta E_i = (g_i - y^{(i)})X^{(i)}$。含义：$(g_i - y^{(i)})$ 是“预测概率 − 真实标签”的误差，误差为正说明应该把 $X^\top\Theta$ 往小了调（梯度指向增大方向，更新时减去）；乘以样本 $X^{(i)}$ 给出“每个特征该负多少责任”——特征越大，该样本的误差对这个特征的调整越大。
4. 损失 $= -\ln\sigma(0) = -\ln 0.5 = \ln 2 \approx 0.693$；梯度 $= (\sigma(0) - 1)X^{(\text{样本})} = -0.5\,X^{(\text{样本})}$，方向与样本向量 X 相反。

3 支持向量机（Lecture 4）

本章学习目标

- 理解线性分类器与“哪个超平面最好”的问题：**最大间隔**准则；
- 熟练推导 SVM 的原始问题：从“距离”到 $\min \frac{1}{2}\|w\|^2$ s.t. 间隔约束；
- 掌握**拉格朗日乘子法、对偶问题、KKT 条件**这条工具链，并能完整推导 SVM 对偶问题；
- 会用 KKT 互补松弛条件解释**支持向量**，能从 α^* 还原 w^*, b^*；
- 理解**核技巧**：为什么高维映射 + 内积 = 核函数，典型核函数及其计算优势；
- 理解**软间隔 SVM** 与合页损失（hinge loss）的动机。

3.1 线性分类器回顾

分类的目标：给定带类别标签的样本集合，学习一个分类器，自动识别新样本。**线性分类器**：基于特征的线性组合做决策，用一张超平面把输入空间切成两半，一侧一类。

最简单的二分类例子：

$$h(x) = w^\top x + b \text{ 定义一张超平面;} \qquad \begin{cases} w^\top x + b > 0 & \Rightarrow \text{ 预测为正类（如 } +1) \\ w^\top x + b < 0 & \Rightarrow \text{ 预测为负类（如 } -1) \end{cases}$$

即预测输出 $\text{sign}(w^\top x + b)$。

3.2　SVM 的目标：最宽的路

支持向量机是理论上最有根据、实践中最有效的线性分类器之一。

设二维数据集 $D=\{(x_1,y_1),\dots,(x_m,y_m)\}$（本讲沿用讲义记号：$x_i$ 为样本、$y_i\in\{+1,-1\}$），超平面 $w^\top x+b=0$。若数据线性可分，则有无穷多张超平面能分开数据——**哪一张“最好”?**

答案是：**离最近点最远的那张**（讲义图最右侧）。为什么?

核心直觉：间隔 = 容错空间

决策边界离最近的样本距离越大，对噪声的容忍度越高，分类器越*稳健*。这条路要尽量“宽”（fat margin）。SVM 的目标就是找到**最宽的分离路**。

点到超平面的距离。　样本 x_i 到超平面 $w^\top x+b=0$ 的几何距离为

$$\gamma=\frac{\left|w^\top x_i+b\right|}{\|w\|}. \tag{16}$$

用标签消掉绝对值。　约定分类规则 $y_i=+1$ 当 $w^\top x_i+b>0$，$y_i=-1$ 当 $w^\top x_i+b<0$。于是总有 $y_i(w^\top x_i+b)=\left|w^\top x_i+b\right|$，几何距离可写成

$$\gamma=\frac{y_i(w^\top x_i+b)}{\|w\|}.$$

函数间隔的尺度自由度与归一化。　注意 (w,b) 与 $(\varsigma w,\varsigma b)$（$\varsigma>0$）定义同一张超平面，但函数间隔会被缩放。因此可以**不失一般性地缩放**（“固定尺度”）：让离超平面最近的样本满足

$$y_i(w^\top x_i+b)\geq 1.$$

等号在最近的样本处取到(它们决定了间隔的宽度)——这些关键样本称为**支持向量**(support vector)。对支持向量 (x_s,y_s)：$y_s(w^\top x_s+b)=1$。

为什么可以令最近点间隔为 1?

w,b 同时缩放不影响超平面本身，只影响函数间隔数值。我们约定“用一组缩放后的参数使最近点函数间隔恰为 1”，这只是选定一个方便的刻度；几何间隔 $\frac{2}{\|w\|}$ 才是与刻度无关的真实宽度。

间隔与目标函数。　正、负支持向量到超平面的距离都是

$$\frac{y_s(w^\top x_s+b)}{\|w\|}=\frac{1}{\|w\|},$$

两侧相加得**间隔（margin）**

$$\gamma=\frac{2}{\|w\|}. \tag{17}$$

寻找最宽的路 = 最大化 γ：

$$\max_{w,b}\frac{2}{\|w\|}\qquad\text{s.t.}\qquad y_i(w^\top x_i+b)\geq 1,\ \forall i.$$

等价变形：$\max\frac{2}{\|w\|}\iff\min\frac{1}{2}\|w\|\iff\min\frac{1}{2}\|w\|^2$（后者求导更简洁）。最终得到 SVM 的**原始优化问题**：

$$\boxed{\min_{w,b}\ \frac{1}{2}\|w\|^2\qquad\text{s.t.}\qquad g_i(w,b)=1-y_i\big(w^\top x_i+b\big)\leq 0,\ i=1,\dots,m} \tag{18}$$

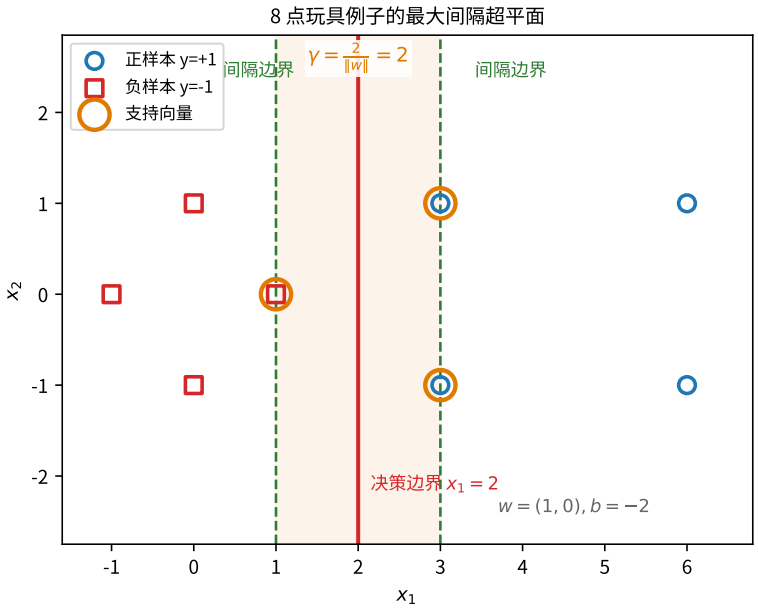


图 7: 8 点玩具例：最优超平面 $x_1 = 2$、两条间隔边界 $x_1 = 1$ 与 $x_1 = 3$、三个支持向量（橙色圈）；间隔 $\gamma = \frac{2}{\|w\|} = 2$。

3.3　工具准备：拉格朗日乘子、对偶、KKT

拉格朗日乘子法（等式约束）。　考虑

$$\min_{w} f(w) \quad \text{s.t.} \quad h_j(w) = 0,\ j = 1, \dots, l.$$

构造**拉格朗日函数**

$$L(w, \beta) = f(w) + \sum_{j=1}^{l} \beta_j h_j(w),$$

则带约束问题的极值点 $= L$ 的无约束极值点（$L(w^*, \beta^*) = f(w^*)$）：

$$\frac{\partial L}{\partial w} = \nabla_w f + \sum_j \beta_j \nabla_w h_j = 0, \qquad \frac{\partial L}{\partial \beta_j} = h_j(w) = 0.$$

例题 3.1　补充例：等式约束最小值（讲义示例）

$$\min_{x_1, x_2} \ 2x_1^2 + x_2^2 \qquad \text{s.t.} \qquad x_1 + x_2 = 1.$$

拉格朗日函数 $L = 2x_1^2 + x_2^2 + \beta_1(x_1 + x_2 - 1)$。求偏导置零：

$$\frac{\partial L}{\partial x_1} = 4x_1 + \beta_1 = 0, \quad \frac{\partial L}{\partial x_2} = 2x_2 + \beta_1 = 0, \quad \frac{\partial L}{\partial \beta_1} = x_1 + x_2 - 1 = 0.$$

由前两式 $x_1 = -\frac{\beta_1}{4}$，$x_2 = -\frac{\beta_1}{2}$，代入第三式：$-\frac{3\beta_1}{4} = 1 \Rightarrow \beta_1 = -\frac{4}{3}$，于是 $x_1^* = \frac{1}{3}$，$x_2^* = \frac{2}{3}$。检验：目标值 $2 \cdot \frac{1}{9} + \frac{4}{9} = \frac{2}{3}$，而约束线上的点 $(t, 1-t)$ 目标为 $2t^2 + (1-t)^2 = 3t^2 - 2t + 1$，在 $t = \frac{1}{3}$ 取最小 $\frac{2}{3}$。✓

广义拉格朗日与对偶。 混合不等式与等式约束：

$$\min_w f(w) \quad \text{s.t.} \quad g_i(w) \le 0 \ (i = 1..k), \quad h_j(w) = 0 \ (j = 1..l)$$

（称为**原始问题**，primal）。定义**广义拉格朗日函数**：

$$L(w, \alpha, \beta) = f(w) + \sum_{i=1}^{k} \alpha_i g_i(w) + \sum_{j=1}^{l} \beta_j h_j(w).$$

考虑 $\theta_P(w) = \max_{\alpha \ge 0, \beta} L(w, \alpha, \beta)$：

- 若 w 违反约束（某 $g_i(w) > 0$，可取 $\alpha_i \to \infty$；或 $h_j(w) \ne 0$），则 $\theta_P(w) = \infty$；
- 若 w 满足约束，则不等式项 ≤ 0 被 $\alpha \ge 0$ 乘后取 max 时全部取 0，$\theta_P(w) = f(w)$。

于是

$$\theta_P(w) = \begin{cases} f(w), & w \text{ 满足约束} \\ \infty, & \text{否则} \end{cases} \qquad \Longrightarrow \qquad \text{原始问题} = \min_w \theta_P(w) = \min_w \max_{\alpha \ge 0, \beta} L(w, \alpha, \beta) = p^*.$$

对偶问题：交换 max/min 顺序，

$$\theta_D(\alpha, \beta) = \min_w L(w, \alpha, \beta), \qquad \text{对偶问题} = \max_{\alpha \ge 0, \beta} \theta_D = \max_{\alpha \ge 0, \beta} \min_w L(w, \alpha, \beta) = d^*.$$

一般有**弱对偶**（max-min 不等式）：

$$d^* = \max_{\alpha \ge 0, \beta} \min_w L \ \le \ \min_w \max_{\alpha \ge 0, \beta} L = p^*.$$

在特定条件下达到**强对偶** $d^* = p^*$，就可以通过解对偶问题代替原始问题。

KKT 条件。 若 w^* 与 α^*, β^* 分别是原始、对偶最优解，则强对偶 $d^* = p^*$ 要求它们满足 Karush–Kuhn–Tucker 条件：

$$\frac{\partial}{\partial w} L(w^*, \alpha^*, \beta^*) = 0, \qquad \frac{\partial}{\partial \beta_j} L(w^*, \alpha^*, \beta^*) = 0 \quad (j = 1..l),$$

$$\alpha_i^* g_i(w^*) = 0, \qquad g_i(w^*) \le 0, \qquad \alpha_i^* \ge 0 \quad (i = 1..k).$$

其中 $\alpha_i^* g_i(w^*) = 0$ 称为**互补松弛条件**（dual complementarity），它蕴含：*若 $\alpha_i^* > 0$，则 $g_i(w^*) = 0$*——该约束“紧”地起作用（取等号）。这正是识别支持向量的钥匙。

3.4 SVM 的对偶问题：完整推导

回到 SVM：

$$\min_{w,b} \frac{1}{2} \|w\|^2 \qquad \text{s.t.} \qquad g_i(w, b) = 1 - y_i(w^\top x_i + b) \le 0, \ i = 1..m.$$

每个样本对应一个不等式约束和一个乘子 $\alpha_i \ge 0$（没有等式约束，故没有 β）。构造拉格朗日函数：

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 + \sum_{i=1}^{m} \alpha_i \Big[1 - y_i\big(w^\top x_i + b\big)\Big] = \frac{1}{2} w^\top w + \sum_{i=1}^{m} \Big(\alpha_i - \alpha_i y_i w^\top x_i - \alpha_i y_i b\Big). \quad (19)$$

第一步：对 w, b 求最小（消去 w, b）。　固定 α，令偏导为零：

$$\frac{\partial L}{\partial w} = w - \sum_{i=1}^{m} \alpha_i y_i x_i = 0 \;\Rightarrow\; \boxed{w = \sum_{i=1}^{m} \alpha_i y_i x_i}$$

$$\frac{\partial L}{\partial b} = -\sum_{i=1}^{m} \alpha_i y_i = 0 \;\Rightarrow\; \boxed{\sum_{i=1}^{m} \alpha_i y_i = 0}$$

第二步：把 w, b 代回 L，得到对偶目标。

$$\begin{aligned}
\min_{w,b} L &= \frac{1}{2} w^\top w + \sum_i \alpha_i - \sum_i \alpha_i y_i w^\top x_i - \underbrace{b \sum_i \alpha_i y_i}_{=0} \\
&= \frac{1}{2} w^\top \Big(\sum_i \alpha_i y_i x_i \Big) - \Big(\sum_i \alpha_i y_i x_i \Big)^\top w + \sum_i \alpha_i \\
&= -\frac{1}{2} \Big\| \sum_i \alpha_i y_i x_i \Big\|^2 + \sum_i \alpha_i = \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j \, x_i^\top x_j .
\end{aligned}$$

（第三行用了 $w = \sum_i \alpha_i y_i x_i$，于是 $w^\top w = \sum_i \alpha_i y_i x_i^\top w$。）

第三步：写出对偶问题。

$$\boxed{\max_{\alpha} \; \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i,j=1}^{m} \alpha_i \alpha_j y_i y_j \, x_i^\top x_j \qquad \text{s.t.} \qquad \sum_{i=1}^{m} \alpha_i y_i = 0, \quad \alpha_i \geq 0} \tag{20}$$

这是一个**二次规划**（QP）问题，可用 SMO（Sequential Minimal Optimization，序列最小优化）等高效算法求解。求解得到 α^* 后，由 $w = \sum_i \alpha_i y_i x_i$ 还原

$$w^* = \sum_{i=1}^{m} \alpha_i^* y_i x_i .$$

对 b^*：任取一个支持向量 (x_s, y_s)（$y_s(w^\top x_s + b) = 1$），

$$b^* = \frac{1}{y_s} - w^\top x_s .$$

实践中建议对*所有*支持向量取平均以减小数值误差：

$$b^* = \frac{1}{|S|} \sum_{s \in S} \left(\frac{1}{y_s} - w^\top x_s \right), \qquad S = \{ i : \alpha_i > 0 \}.$$

最终模型：$f(x) = w^\top x + b$，其中 $w = \sum_i \alpha_i y_i x_i$。

KKT 验证——为什么只有支持向量“说话”。　SVM 的 KKT 条件：

$$w = \sum_i \alpha_i y_i x_i, \qquad \alpha_i \geq 0, \qquad y_i(w^\top x_i + b) - 1 \geq 0, \qquad \alpha_i \big(y_i(w^\top x_i + b) - 1 \big) = 0.$$

由互补松弛：

- 若 $y_i(w^\top x_i + b) - 1 > 0$（样本在间隔外、离得足够远），则必须 $\alpha_i = 0$——*该样本对模型完全无贡献*;
- 若 $\alpha_i > 0$，则 $y_i(w^\top x_i + b) - 1 = 0$——*该样本恰在间隔边界上，是支持向量*。

因此预测时

$$f(x) = w^\top x + b = \sum_{i=1}^{m} \alpha_i y_i \, x_i^\top x + b,$$

只有少数支持向量的 $\alpha_i > 0$，只需计算 x 与这些支持向量的内积——这是 SVM 高效的关键之一。

例题 3.2　讲义 Quiz：从 α 找支持向量

8 个数据点：$(7, 1.5), (8, -1), (6.5, 2), (6, -1), (1, 0), (0, 1), (0, -1), (-1, 0)$。已知最优乘子 $\alpha_3 = 0.0266$，$\alpha_4 = 0.0533$，$\alpha_5 = 0.0800$，其余为 0。哪些点是支持向量?

解（选 C）。由互补松弛条件：$\alpha_i > 0 \Rightarrow$ 样本是支持向量。$\alpha_3, \alpha_4, \alpha_5 > 0$，故第 3、4、5 个点是支持向量，且它们的约束取等号：

$$\{(6.5, 2),\ (6, -1),\ (1, 0)\}.$$

其余 $\alpha_i = 0$ 的点都在间隔之外（$y_i(w^\top x_i + b) - 1 > 0$），对模型无影响。

3.5　完整玩具例子：8 点 SVM 手算

问题。　正样本 $(3, 1), (3, -1), (6, 1), (6, -1)$，负样本 $(1, 0), (0, 1), (-1, 0), (0, -1)$。

对偶目标。　$m = 8$:

$$\max_{\alpha} \sum_{i=1}^{8} \alpha_i - \frac{1}{2} \sum_{i,j=1}^{8} \alpha_i \alpha_j y_i y_j \, x_i^\top x_j \qquad \text{s.t.} \qquad \sum_{i=1}^{8} \alpha_i y_i = 0,\ \alpha_i \geq 0.$$

把数据代入（这就是讲义中那个冗长的展开式），用 SMO 工具箱求解得：

$$\alpha_1 = \alpha_2 = 0.25, \qquad \alpha_5 = 0.5, \qquad \alpha_3 = \alpha_4 = \alpha_6 = \alpha_7 = \alpha_8 = 0.$$

还原参数。

$$\begin{aligned} w^* = \sum_{i=1}^{8} \alpha_i y_i x_i &= 0.25\,(3, 1) + 0.25\,(3, -1) - 0.5\,(1, 0) \\ &= (1.5, 0.25) + (0.75, -0.25) + (-0.5, 0) = (1, 0). \end{aligned}$$

三个支持向量：$x_1 = (3, 1)$、$x_2 = (3, -1)$、$x_5 = (1, 0)$；$w = (1, 0)^\top$ 时对应的 $w^\top x_s$ 分别为 $3, 3, 1$。对每个支持向量计算 $\frac{1}{y_s} - w^\top x_s$:

$$s = 1:\ \frac{1}{+1} - 3 = -2; \qquad s = 2:\ \frac{1}{+1} - 3 = -2; \qquad s = 5:\ \frac{1}{-1} - 1 = -2.$$

三者完全一致（这正是最优解的对称性），故

$$b^* = \frac{1}{|S|} \sum_{s \in S} \left(\frac{1}{y_s} - w^\top x_s \right) = -2.$$

最终模型与几何。

$$w = (1,0)^\top, \quad b = -2 \qquad \Rightarrow \qquad f(x) = x_1 - 2.$$

决策边界 $x_1 = 2$；两条间隔边界 $x_1 = 1$ 与 $x_1 = 3$；间隔 $\gamma = \frac{2}{\|w\|} = 2$（见图 7）。

验证（把每个点代进去检查函数间隔）。

	$(3,1)$	$(3,-1)$	$(6,1)$	$(6,-1)$	$(1,0)$	$(0,1)$	$(-1,0)$	$(0,-1)$
$y_i(x_1-2)$	$+1$	$+1$	$+4$	$+4$	$+1$	$+2$	$+3$	$+2$

所有函数间隔 ≥ 1，其中 x_1, x_2, x_5 恰好 $= 1$（支持向量），其余 > 1（$\alpha_i = 0$）。✓

例题 3.3　补充例：三点的最小 SVM（另一个可以完全手算的例子）

数据（一维）：正样本 $x_1 = 1$，$x_2 = 2$；负样本 $x_3 = -1$。由 KKT，非支持向量的乘子为 0；直观上 $x_1 = 1$ 与 $x_3 = -1$ 是最“难分”的一对，设它们为支持向量：$\alpha_1 = \alpha_3 = a \geq 0$，$\alpha_2 = 0$。
等式约束：$\sum_i \alpha_i y_i = a - \alpha_3 + \alpha_2 = 0 \;\Rightarrow\; a = \alpha_3$，自动满足（构造时就取相等）。*对偶目标*：$w = \sum_i \alpha_i y_i x_i = a \cdot (+1)(1) + a \cdot (-1)(-1) = 2a$，

$$f(a) = \sum_i \alpha_i - \frac{1}{2}\|w\|^2 = 2a - \frac{1}{2}(2a)^2 = 2a - 2a^2.$$

求极大：$f'(a) = 2 - 4a = 0 \Rightarrow a^* = \frac{1}{2}$（$f'' < 0$ 确认极大），$f(a^*) = \frac{1}{2}$。*还原*：$w^* = 2a^* = 1$；对支持向量 $b^* = \frac{1}{y_s} - w^\top x_s$：$s = 1$ 给 $1 - 1 = 0$，$s = 3$ 给 $-1 + 1 = 0$，故 $b^* = 0$。
验证：函数间隔 $y_i(wx_i + b)$ 依次为 1 $(+1 \times 1)$，2 $(+1 \times 2)$，1 (-1×-1)：前两个 ≥ 1、$x_2 = 2$ 落在间隔外（因此 $\alpha_2 = 0$ 合理 ✓），x_1, x_3 恰在间隔边界上。模型：$f(x) = x$，决策边界 $x = 0$，间隔 $\gamma = \frac{2}{|w|} = 2$。

3.6　核 SVM：处理非线性数据

问题。　有些数据在原始维度不可线性分开。把维度升高，原本纠缠的两类可能就有“缝隙”了。

显式升维。　例如二维数据升到三维：

$$x = \begin{pmatrix} x^{(1)} \\ x^{(2)} \end{pmatrix} \longmapsto \phi(x) = \begin{pmatrix} (x^{(1)})^2 \\ (x^{(2)})^2 \\ \sqrt{2}\, x^{(1)} x^{(2)} \end{pmatrix},$$

在新空间里模型为 $f(x) = w^\top \phi(x) + b$。相应的优化问题与对偶问题只需把 x_i 换成 $\phi(x_i)$。

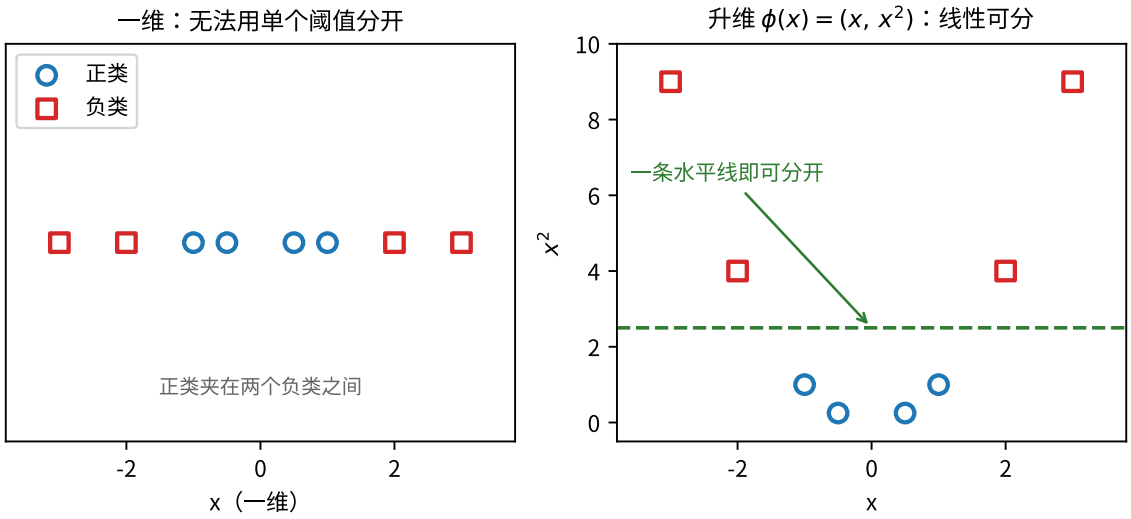


图 8: 升维的威力（一维示意）：左图正类夹在两个负类之间，一维无法用单个阈值分开；右图把每个点映射到 (x, x^2) 后，两类落到了不同高度，一条水平线即可分开。

核技巧。　维度一高，“显式算坐标”的内存与计算代价爆炸。关键观察：对偶问题与预测式里，数据只以**内积** $x_i^\top x_j$（以及 $\phi(x_i)^\top\phi(x_j)$）的形式出现。若存在函数

$$\kappa(x_i, x_j) = \phi(x_i)^\top \phi(x_j) \tag{21}$$

能不显式计算 ϕ 就得到内积，就绕过了高维代价——这就是**核函数**（kernel function）与**核技巧**。

例题 3.4　补充例：核函数确实“更便宜”（讲义例子）

对 $x = (x^{(1)}, x^{(2)})$ 取上面的 ϕ，验证

$$\phi(x_i)^\top\phi(x_j) = (x_i^{(1)}x_j^{(1)})^2 + (x_i^{(2)}x_j^{(2)})^2 + 2x_i^{(1)}x_j^{(1)}x_i^{(2)}x_j^{(2)} = \big(x_i^\top x_j\big)^2.$$

数值验证：$x_i = (1,2)$，$x_j = (3,4)$：$(x_i^\top x_j)^2 = (3{+}8)^2 = 121$；显式 ϕ：$\phi(x_i) = (1, 4, 2\sqrt{2})$，$\phi(x_j) = (9, 16, 12\sqrt{2})$，内积 $= 9 + 64 + 2\cdot 2\sqrt{2}\cdot 12\sqrt{2} = 73 + 48 = 121$。✓ 计算复杂度：显式二次映射后内积需 $O(n^2)$，而 κ 直接算只需 $O(n)$（先算 $x_i^\top x_j$ 再平方）。

核化后的模型与对偶。　对偶问题变为

$$\max_{\alpha} \sum_i \alpha_i - \frac{1}{2}\sum_{i,j}\alpha_i\alpha_j y_i y_j\,\kappa(x_i, x_j) \qquad \text{s.t.} \qquad \sum_i \alpha_i y_i = 0,\ \alpha_i \geq 0,$$

预测函数变为

$$f(x) = w^\top\phi(x) + b = \sum_{i=1}^{m}\alpha_i y_i\,\phi(x_i)^\top\phi(x) + b = \sum_{i=1}^{m}\alpha_i y_i\,\kappa(x, x_i) + b.$$

例题 3.5　讲义 Quiz：哪个函数是核?

对变换 $\phi(x) = \big((x^{(1)})^2,\ (x^{(2)})^2,\ \sqrt{2}x^{(1)}x^{(2)}\big)$，以下哪个 κ 满足 $\kappa(x_i, x_j) = \phi(x_i)^\top\phi(x_j)$?（C、D 两个选项在讲义 PDF 的文本提取中残缺，此处按可辨认形式列出，不影响作答。）

(A)　$\kappa(x_i, x_j) = x_i^\top x_j$

(B)　$\kappa(x_i, x_j) = \left(x_i^\top x_j\right)^2$

(C)　$\kappa(x_i, x_j) = x_i^\top x_j + \cdots$（残缺）

(D)　$\kappa(x_i, x_j) = \dfrac{x_i^\top x_j}{\sqrt{\cdots}}$（残缺）

(E)　$\kappa(x_i, x_j) = \sqrt{2}\, x_i^\top x_j$

解（选 B）。上面已完整验证

$$\begin{aligned}(x_i^\top x_j)^2 &= (x_i^{(1)}x_j^{(1)} + x_i^{(2)}x_j^{(2)})^2 \\ &= (x_i^{(1)})^2(x_j^{(1)})^2 + (x_i^{(2)})^2(x_j^{(2)})^2 + 2x_i^{(1)}x_j^{(1)}x_i^{(2)}x_j^{(2)} \\ &= \phi(x_i)^\top \phi(x_j). \quad \blacksquare\end{aligned}$$

常用核函数（讲义表格内容）。

名称	形式	说明
线性核	$\kappa(x_i, x_j) = x_i^\top x_j$	不升维，等价于原始线性 SVM
多项式核	$\kappa(x_i, x_j) = (x_i^\top x_j + c)^d$	$c \geq 0$ 控制低阶项，d 为阶数
高斯核（RBF）	$\kappa(x_i, x_j) = \exp\left(-\gamma \left\|x_i - x_j\right\|^2\right)$	无穷维特征空间，$\gamma > 0$
Sigmoid 核	$\kappa(x_i, x_j) = \tanh(\alpha x_i^\top x_j + c)$	与神经网络有联系

例题 3.6　补充例：高斯核的数值与直觉

$x_i = (1,2),\ x_j = (3,4), \gamma = 0.5$: $\|x_i - x_j\|^2 = (2)^2 + (2)^2 = 8, \kappa = \exp(-0.5 \times 8) = e^{-4} \approx 0.0183$。直觉：两个点离得越远，核值越小，相似度越低；离得近（距离 $\to 0$）时核值 $\to 1$。高斯核把每个样本变成“相似度中心”，可理解为在*无穷维*空间做内积。

3.7　软间隔 SVM：允许一点噪声

动机。　有时找不到合适的核使数据完全可分；即使找到了，硬性要求“全部分对、间隔内无点”容易**过拟合**。这时放弃几个噪声样本是合理的。

从硬约束到软约束。　原来要求 $y_i(w^\top x_i + b) \geq 1$（对所有 i）。软间隔思想：对“听话”的样本保持 ≥ 1；对少数噪声样本放宽约束。用 0/1 损失计数：

$$\min_{w,b}\ \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{m} l_{0/1}\Big(y_i(w^\top x_i + b) - 1\Big), \qquad l_{0/1}(z) = \begin{cases} 1, & z < 0 \\ 0, & z \geq 0 \end{cases}$$

约束满足时 $l_{0/1} = 0$；违反时罚 1，C 控制惩罚强度。

换成 hinge 损失。　$l_{0/1}$ 非凸、不连续，优化困难。常用替代函数是**合页损失**（hinge loss）：

$$\min_{w,b}\ \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{m} \max\Big(0,\ 1 - y_i(w^\top x_i + b)\Big).$$

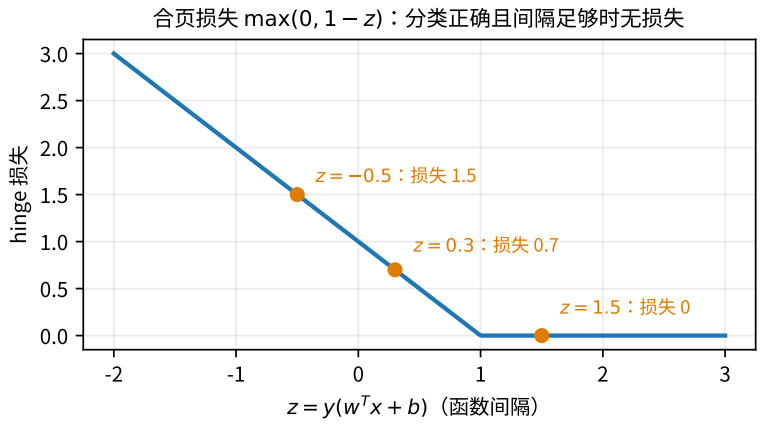


图 9: 合页损失 $\max(0, 1-z)$（$z = y(w^\top x + b)$）：$z \geq 1$ 时零损失，$z < 1$ 时线性惩罚。

例题 3.7　补充例：hinge 损失数值

函数间隔 $z = y(w^\top x + b)$：

$$z = 0.3 \;\Rightarrow\; \max(0, 1-0.3) = 0.7; \qquad z = 1.5 \;\Rightarrow\; 0; \qquad z = -0.5 \;\Rightarrow\; 1.5.$$

直观：$z \geq 1$（分类正确且间隔足够）不罚；$0 \leq z < 1$（分类对但不够自信）轻罚；$z < 0$（分类错）重罚，而且错得越离谱罚得越重。

三种模型的“loss 家族”小结

线性回归用平方损失；逻辑回归用交叉熵（$y = \pm 1$ 写法下等价 logistic 损失）；SVM 用 hinge 损失。三者对“错误”的惩罚形状不同：平方温和、交叉熵对自信错误指数级陡、hinge 线性——哪种更合适取决于任务与噪声假设。

3.8　本章小结

SVM 一页总结

- **目标**：找最宽间隔超平面 $\Rightarrow \min \frac{1}{2}\|w\|^2$ s.t. $y_i(w^\top x_i + b) \geq 1$；
- **对偶**：$\max_\alpha \sum \alpha_i - \frac{1}{2}\sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^\top x_j$ s.t. $\sum \alpha_i y_i = 0, \alpha_i \geq 0$（QP，用 SMO 解）；
- **还原**：$w^* = \sum_i \alpha_i y_i x_i$，$b^*$ 由支持向量平均；
- **支持向量**：$\alpha_i > 0 \iff$ 样本在间隔边界上（KKT 互补松弛）；
- **核技巧**：$\kappa(x_i, x_j) = \phi(x_i)^\top \phi(x_j)$，只用内积，跳过显式升维；
- **软间隔**：$+ C \sum \max(0, 1 - y_i(w^\top x_i + b))$——允许少量噪声，抗过拟合。

对应讲义与阅读。 Lecture 4 全部内容（含补充页：Lagrange 乘子、duality、KKT、详细推导）；NTU 线性 SVM / 核 SVM 讲义；Stanford SVM 讲义（CS229 notes 3）；SVM 原始论文（Cortes & Vapnik, 1995）。

自检题（SVM）

1. 为什么 SVM 要把超平面“归一化”到 $y_i(w^\top x_i + b) \geq 1$？这个 1 是真实距离吗？

2. 已知最优解 $w=(3,4)^\top, b=-5$。写出决策边界方程、计算 $\|w\|$ 与间隔 γ；点 $(3,4)$ 在边界的哪一侧？函数间隔是多少？

3. 用自己的话解释 KKT 条件 $\alpha_i(y_i(w^\top x_i+b)-1)=0$ 为什么让“非支持向量不起作用”。

4. 多项式核 $\kappa=(x_i^\top x_j)^2$ 对应几维特征空间中的内积？相比显式计算 ϕ，计算复杂度差多少？

答案

1. 因为 (w,b) 整体缩放不改变超平面，函数间隔具有尺度自由度；约定“最近点为 1”只是固定刻度，使间隔表达式简化为 $\gamma=\frac{2}{\|w\|}$。几何间隔 $\frac{2}{\|w\|}$ 才是与刻度无关的真实宽度；“1”只是函数间隔的刻度读数。

2. 边界：$3x_1+4x_2-5=0$。$\|w\|=\sqrt{9+16}=5, \gamma=\frac{2}{5}=0.4$。代入 $(3,4)$：$3\cdot3+4\cdot4-5=20>0$，在正侧；函数间隔（$y=+1$ 时）$=20$。（几何上到超平面的距离 $=\frac{20}{5}=4$。）

3. 若某点不在间隔边界上（函数间隔 >1），互补松弛迫使 $\alpha_i=0$，该点在对偶目标和 $w=\sum_i \alpha_i y_i x_i$ 里权重为零——加不加它、挪动它都不改变解；反之只有 $\alpha_i>0$ 的点（支持向量）决定边界。

4. 对应 3 维（$n=2$ 时：$(x^{(1)})^2,(x^{(2)})^2,\sqrt{2}x^{(1)}x^{(2)}$）；一般 n 维时有 $O(n^2)$ 个二次项。显式算 ϕ 再内积需 $O(n^2)$，用核先内积再平方只需 $O(n)$。

4 总结、速查表与易错点

4.1 三讲公式速查表

一、线性回归（Lecture 2）

模型	$\hat{Y}=X\Theta$；一元：$\hat{y}=\theta_1 x+\theta_0$（$X$ 左侧拼一列全 1）
损失	$J(\Theta)=\|X\Theta-Y\|_2^2=\sum_{i=1}^{m}(\hat{y}^{(i)}-y^{(i)})^2$（RSS）
解析解	$X^\top X\Theta=X^\top Y \Rightarrow \hat{\Theta}=(X^\top X)^{-1}X^\top Y$
一元闭式	$\theta_1=\frac{\sum_i(x^{(i)}-\bar{x})(y^{(i)}-\bar{y})}{\sum_i(x^{(i)}-\bar{x})^2}=\frac{S_{xy}}{S_{xx}}, \quad \theta_0=\bar{y}-\theta_1\bar{x}$
可逆条件	$X^\top X$ 可逆 $\iff$ X 列线性无关；保证条件：$m\geq n+1$
误差分解	$\mathrm{EPE}(X)=\mathrm{Bias}^2+\mathrm{Var}+\sigma^2$
岭回归	$\hat{\Theta}=\arg\min_\Theta \|X\Theta+\theta_0-Y\|_2^2+\lambda\|\Theta\|_2^2$（单变量闭式 $\theta_1^{\mathrm{ridge}}=\frac{S_{xy}}{S_{xx}+\lambda}$）
Lasso	$\hat{\Theta}=\arg\min_\Theta \|X\Theta+\theta_0-Y\|_2^2+\lambda\|\Theta\|_1$（$\|\Theta\|_1=\sum_j\|\theta_j\|$）

二、逻辑回归（Lecture 3）

变换	$\mathrm{odds}(p)=\frac{p}{1-p}$；$\mathrm{logit}(p)=\ln\frac{p}{1-p}$；$\mathrm{logit}^{-1}(z)=\sigma(z)=\frac{1}{1+e^{-z}}$
模型	$P(\hat{y}=1\|X)=\sigma(X^\top\Theta)$；判 $\hat{y}=1 \iff X^\top\Theta\geq 0$
sigmoid	$\sigma(0)=0.5$；单调递增；$\sigma'(z)=\sigma(z)\big(1-\sigma(z)\big)\in(0,\frac{1}{4}]$
损失	$E(\Theta)=-\sum_{i=1}^{m}\Big[y^{(i)}\ln g_i+(1-y^{(i)})\ln(1-g_i)\Big]$，$g_i=\sigma(X^{(i)\top}\Theta)$ （交叉熵 / 负对数似然）
梯度	$\nabla E(\Theta)=\sum_{i=1}^{m}\big(g_i-y^{(i)}\big)X^{(i)}$
更新式	$\Theta\leftarrow\Theta-\alpha\nabla E(\Theta)$；凸目标 + 梯度下降 $\Rightarrow$ 全局最优
Hessian	$H_i=g_i(1-g_i)\,X^{(i)}X^{(i)\top}\succeq 0$（凸性来源）

三、支持向量机（Lecture 4）

点到面距离	$\gamma=\dfrac{\lvert w^\top x+b\rvert}{\|w\|}$；结合标签 y_i 可去绝对值
原始问题	$\min\limits_{w,b}\dfrac{1}{2}\|w\|^2\quad\text{s.t.}\quad y_i(w^\top x_i+b)\geq 1$
间隔	$\gamma=\frac{2}{\|w\|}$（两条间隔边界之间的距离）
对偶问题	$\max\limits_{\alpha}\sum\limits_i\alpha_i-\dfrac{1}{2}\sum\limits_{i,j}\alpha_i\alpha_j y_i y_j\,x_i^\top x_j\quad\text{s.t. }\sum_i\alpha_i y_i=0,\ \alpha_i\geq 0$
还原参数	$w^*=\sum_i\alpha_i y_i x_i$；$b^*=\dfrac{1}{\lvert S\rvert}\sum\limits_{s\in S}\Big(\dfrac{1}{y_s}-w^\top x_s\Big)$
支持向量	$\alpha_i>0\iff y_i(w^\top x_i+b)=1$（KKT 互补松弛）
核 SVM	$f(x)=\sum_i\alpha_i y_i\,\kappa(x,x_i)+b$，$\kappa(x_i,x_j)=\phi(x_i)^\top\phi(x_j)$
软间隔	$\min\limits_{w,b}\dfrac{1}{2}\|w\|^2+C\sum\limits_i\max\big(0,1-y_i(w^\top x_i+b)\big)$（hinge 损失）

4.2 讲义 Quiz 全解索引

出处	题目	答案	关键步骤
L2 Slide 28	用最小二乘拟合 $y=\theta_1 x+\theta_0$ 到 $(9,21),(3,6),(12,27)$	B	$S_{xy}=99$，$S_{xx}=42$，$\theta_1=99/42\approx 2.3571$，$\theta_0=-6/7\approx -0.8571$
L3 Slide 60	$f(\theta)=\theta^2$，$\alpha=0.4$，$\theta_0=10$，$\lvert f(\theta^*)-f(\theta)\rvert\le 0.01$ 至少几次迭代	B	更新因子 $1-0.8=0.2$：$10\to 2\to 0.4\to 0.08$；第 3 次 $f=0.0064\le 0.01$
L4 Slide 30	已知 $\alpha_3,\alpha_4,\alpha_5>0$，哪些是支持向量	C	互补松弛：$\alpha_i>0$ 的点即支持向量，即第 3、4、5 点 $(6.5,2),(6,-1),(1,0)$
L4 Slide 39	$\phi(x)=\big((x^{(1)})^2,(x^{(2)})^2,\sqrt{2}x^{(1)}x^{(2)}\big)$ 对应哪个核	B	展开 $(x_i^\top x_j)^2$ 逐项等于 $\phi(x_i)^\top\phi(x_j)$

4.3 常见易错点清单（考前自查）

十大高频错误

1. **RSS 梯度差一个转置/系数**：记住 $\nabla_\Theta\|X\Theta-Y\|^2=2X^\top(X\Theta-Y)$，正规方程里 $X^\top X$ 在左侧、$X^\top Y$ 在右侧。
2. **忘记吸收偏置**：写矩阵形式时先给 X 拼全 1 列、给 Θ 加 θ_0 分量，之后所有公式（解析解、梯度）都用简写形式；忘记这一步会导致维度对不上。
3. **把“函数间隔”当“几何距离”**：$\frac{y_i(w^\top x_i+b)}{\|w\|}$ 才是几何距离；SVM 里把最近点函数间隔归一化为 1，只是选刻度。
4. **间隔写成 $\frac{1}{\|w\|}$**：那是单侧距离；两侧相加才是 $\gamma=\frac{2}{\|w\|}$，别漏乘 2。
5. **混淆 α_i 与 y_i**：$y_i\in\{+1,-1\}$ 是标签；$\alpha_i\ge 0$ 是拉格朗日乘子；只有 $\alpha_i>0$ 的点才是支持向量。
6. **b^* 展开时符号错**：对支持向量 $y_s(w^\top x_s+b)=1\Rightarrow b=\frac{1}{y_s}-w^\top x_s$；$\frac{1}{y_s}=\pm 1$，不是 y_s 的其他组合。（代回原式验证一遍最保险。）
7. **sigmoid 导数记错**：$\sigma'(z)=\sigma(z)(1-\sigma(z))$，最大值 0.25 在 $z=0$；不要写成 $\sigma(z)\sigma(-z)$ 之外的东西（两者恰好相等，但来源要清楚）。
8. **梯度下降忘记负号**：更新是 $\Theta\leftarrow\Theta-\alpha\nabla f$（减去梯度 = 朝下降方向）；$\nabla f$ 指向上升最快的方向。
9. **把交叉熵当“随便一个损失”**：它的形式直接来自最大似然（负对数似然），推导路径 = 独立样本乘积 $\to$ 取对数变和 $\to$ 加负号。
10. **核函数“升级”成万能借口**：核必须对应某个内积空间（半正定核矩阵）才合法；判断题常用“展开成 $\phi^\top\phi$ 逐项对照”的方法，如 $(x^\top z)^2$ 对应二次映射。

4.4 三讲对照总表

	线性回归	**逻辑回归**	**SVM**
输出	连续值 $\hat{y} \in \mathbb{R}$	概率 $P(\hat{y} = 1\|X) \in (0,1)$	类别（决策边界）
假设	线性函数	线性打分 + sigmoid	最大间隔超平面
损失	平方误差 RSS	交叉熵（NLL）	hinge（软间隔）
求解	正规方程（解析）	梯度下降（迭代）	对偶 QP + SMO（凸）
几何	$\hat{Y} = Y$ 在列空间的正交投影	决策边界 = 超平面 $X^\top\Theta = 0$	间隔最宽的分离超平面
关键技巧	矩阵微分、投影	MLE、凸性、方向导数	拉格朗日对偶、KKT、核技巧
复杂度控制	岭回归 / Lasso	（可加正则）	软间隔参数 C、核选择

4.5 建议的复习路径

1. **第一轮（理解）**：按本指南第 1→2→3 章顺序阅读，重点看每个“核心结论”（蓝框）与“例题”；对每个推导，自己在纸上重推一遍（RSS 配方、正规方程、logit 反函数、SVM 对偶）。
2. **第二轮（动手）**：把每章的“补充例”当作练习——先遮住解答自己做，再对照；尤其推荐：手算 LR Quiz、八点 SVM 玩具例、核函数验证。
3. **第三轮（回顾）**：只看本章的公式速查表与易错点清单，做每章末的自检题；若某题卡壳，回到对应小节。
4. **考前**：默写三个模型的“模型–损失–优化”三件套，以及 SVM 对偶推导的四个步骤（构造 $L \to \partial L/\partial w = \partial L/\partial b = 0 \to$ 代回 $\to$ 写出 max 形式）。

一句话记住三讲

线性回归：$\hat{Y} = X\Theta$，“投影 + 正规方程”；**逻辑回归**：$\sigma(X^\top\Theta)$，“似然 $\to$ 交叉熵 $\to$ 梯度下降”；**SVM**：$\min \frac{1}{2}\|w\|^2$，“最大间隔 $\to$ 对偶 $\to$ KKT $\to$ 核”。